

# Latent Retriever for Weakly Supervised Open Domain Question Answering

Songwon Park

[xlah1386@gs.cwnu.ac.kr](mailto:xlah1386@gs.cwnu.ac.kr)

2024. 10 30.

### Latent Retriever for Weakly Supervised Open Domain Question Answering

- **Kenton Lee, Ming-Wei Chang, Kristina Toutanova**  
( google Research )
- **Findings of the Association for Computational Linguistics: ACL 2019**
- [paper](#)

## 메인 아이디어

ICT(Inverse Cloze Task)를 이용해 사전학습하여 retriever와 reader가 end-to-end 학습이 가능하도록 한다.

- 오픈 도메인 질의응답(Open Domain Question Answering) 연구들은 유용한(정답이 포함된) 데이터를 가지고 이루어지는 강력한 지도학습이나 black-box IR(Information Retrieval) 시스템으로 수행됨.
- gold evidence가 항상 주어지는 것이 아니고, QA와 IR(Information Retrieval)가 근본적으로 다르기 때문에 두 방법(강력한 지도학습 / IR system) 모두 최적이지 않음.



- ICT(Inverse Cloze Task)를 이용해 사전학습을 진행한다.
- QA 문자열 쌍만을 이용해 IR 시스템 없이 end-to-end 학습하는 것이 가능하다.

**Open Domain Question Answering**

: 많은 정보들을 포함하고 있는 대량의 문서들로부터 주어진 질문에 대한 답변을 찾는 문제. 질문이 어떤 도메인에 해당되는지, 어떤 키워드인지에 대한 힌트는 없음

**End - to - End 학습**

: 입력에서 출력까지 파이프라인 네트워크 없이 신경망으로 한 번에 처리하는 방식

**Black Box**

: 입,출력 값이 아닌 내부의 인과관계와 같은 구조를 명확히 알 수 없다는 의미

**evidence가 입력으로 주어지는 것이 아닌, open corpus에서 검색해야 하는 Open Domain QA**  
**현재 대부분 접근 방식 : IR**

**- IR (Information Retrieval)**

- 키워드를 기반으로 원하는 문서 검색. 어휘적, 의미론적 매칭과 관련됨.

**- QA (Question Answering)**

- Question, evidence가 주어지면 QA system이 적절한 answer 출력.
- 보다 구체적이고 언어 이해적 측면. (unknown information을 찾으려 함. 매칭과 다름)

**- strongly supervised setting**

- question, answering 쌍과 함께 정답이 주어진 gold evidence가 주어지는 경우

**- weakly supervised setting**

- question, answering 쌍이 주어지고 noisy gold evidence가 주어지는 경우

## Problem

### 1. Open corpus에서 evidence를 찾으려 함

- 답변을 위한 evidence가 데이터셋에 함께 주어지지 않고, open corpus(like Wikipedia)로부터 검색하는 것이 현실과 적합

### 2. IR system 결과물에 의존

- but QA와 IR은 다름

| Example                                                                                        | Supportive Evidence                                                                                | Spurious Ambiguity                                                                                  |
|------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------|
| <b>Q:</b> Who is credited with developing the XY coordinate plane?<br><b>A:</b> René Descartes | ...invention of Cartesian coordinates by <b>René Descartes</b> revolutionized...                   | ... <b>René Descartes</b> was born in La Haye en Touraine, France...                                |
| <b>Q:</b> How many districts are in the state of Alabama?<br><b>A:</b> seven                   | ...Alabama is currently divided into <b>seven</b> congressional districts, each represented by ... | ...Alabama is one of <b>seven</b> states that levy a tax on food at the same rate as other goods... |

Supportive Evidence와 Spurious Ambiguity 모두 “Rene Descartes” 포함

자신과 모호한 지문을 구분할 수 있는 근거/신호를 제공해야 함.

Wikipedia에서 많은 관련 없는(정답이 아닌) passage들이 정답 “seven”을 포함할 수 있음.  
(Apple이 사과 or 기업의 의미가 될 수 있음)



Table 2: Examples of spurious ambiguities arising from the use of weak supervision. Good evidence retrieval is needed to generate a meaningful learning signal.

## Unsupervised 사전학습을 거친 retriever를 이용


1. 모든 evidence block을 미리 인코딩해 fine-tuning시에 빠른 top-k 검색 가능
2. retrieval의 bias를 Spurious Ambiguity에서 Support Evidence로 조정 가능



기존 IR system에 의존하지 않고 QA에 적합한, end-to-end 학습 가능한 파이프라인 제안

## Inverse Cloze Task

- 문장이 주어지면 그에 해당하는 evidence를 예측



q : pseudo - question


BATCH : 한 배치 내의 evidence block들의 집합

B : BATCH

\* 기본적인 Cloze Task : context에서 masking 된 단어를 예측

## Inverse Cloze Task

- 문장이 주어지면 그에 해당하는 evidence를 예측



- Pseudo question에 “**zebra**”가 없더라도 관련된 0번째 context를 선택해야 함
- 질문에 나타나지 않은, 그러나 의미론적으로 관련 있는 문서를 검색할 수 있어야 함

q : pseudo - question

BATCH : 한 배치 내의 evidence block들의 집합

B : BATCH

\* 기본적인 Cloze Task : context에서 masking 된 단어를 예측

- 각 문서의 b에서 랜덤한 문장 q 추출
- 각 BERT 임베딩을 대조학습

$$P_{ICT}(b \mid q) = \frac{\exp(S_{retr}(b, q))}{\sum_{b' \in BATCH} \exp(S_{retr}(b', q))}$$

q : They are generally slower than horses, but their great stamina helps them outrun predators.

b : ... Zebras have four gaits: walk, trot, canter and gallop. When chased, a zebra will zigzag from side to side to side ...

## ICT가 이루어낸 목표

1. 사전학습 시 질문과 fine-tuning 시 질문의 차이에도 zero - shot evidence retrieval 성능을 기대한다.
  - 사전학습 시 질문은 문장의 일부분. fine-tuning 시 질문은 사용자가 생성한 문장 (관련 context를 찾는데 더 어려울 것)
2. fine-tuning 시 evidence block과 사전학습된 evidence block에는 차이 없다.
  - evidence block encoder는 더 학습 시킬 필요 없음.

➡ 짧은 추론 시간 + end-to-end 학습을 실제로 실행 가능하게 하는 데 매우 중요



## Open-Retrieval Question Answering

- Open corpus에서 evidence를 찾아내도록 학습하는 것이 목적
  - IR system이 반환하는 closed set에 제한되지 않고 open corpus의 모든 텍스트를 검색 가능
- QA 쌍으로만 수행



Retriever를 포함하여 end to end 학습 시킬 때 ICT(Inverse Cloze Task)를 이용해 사전학습 후 fine tuning하는 것이 좋은 효과 발생

$$S(b, s, q) = S_{retr}(b, q) + S_{read}(b, s, q)$$

주어진 q에 대한 정답후보 (b,s)가 얼마나 좋은지 =  
retriever가 주어진 q에 대해 block b를 얼마나 잘 찾았는가  
+  
retriever가 찾은 block b 내의 span이 얼마나 적절한가

$$a^* = \underset{b,s}{\text{TEXT}}(\text{argmax } S(b, s, q))$$

score가 최대가 되게 하는 block b와 그 안의 span이 조합된 text string





Figure1. ORQA가 파생된 답변에 점수를 매기는 방법

- Question  $q$ 가 주어졌을 때 선택될 수 있는 모든 답안 (Wikipedia)
- 검색점수 (내적하여 계산)
- 질문과 함께 공동으로 인코딩 됨
- MLP(Multi Layer Perceptron)으로 매겨진 점수

## Retrieval Component




- retrieval 점수: question  $q$ 와 evidence block  $b$ 에 대한 BERT encoder output(벡터)의 내적 곱으로 정의
- 점수 계산 한 후 top k 추출
- $W_q, W_b$  : BERT 출력을 128차원 벡터로 변환하는 역할
  - BERT의 output vector 768차원에서 128차원으로 축소되는 이유는 최종 모델에 단일 머신에서 돌아갈 수 있도록 하기 위함

$$h_q = W_q BERT_Q(q) [CLS]$$

$$h_b = W_b BERT_B(b) [CLS]$$

$$S_{retr}(b, q) = h_q^T h_b$$

## Reader Component



- reader 점수 : top k개의 block에 대해 question과 evidence block을 붙인 것의 BERT encoding output(벡터) 중 span의 시작지점과 끝지점을 Multi-Layer Perceptron(MLP)의 input으로 이용해 계산

$$h_{start} = BERT_R(q, b) [START(s)]$$

$$h_{end} = BERT_R(q, b) [END(s)]$$

$$S_{read}(b, s, q) = MLP([h_{start}; h_{end}])$$

- 가능한 정답의 확률 분포
  - 분자 : 주어진  $q$ 에 대한 block  $b$ , span  $s$ 의 score
  - 분모 : retriever로 검색한 top  $k$ 개의 block  $b$  중 span  $s$ 의 score의 총합
  - $b' \in TOP(K) : S_{retr}$ 에서 뽑힌 상위  $k$ 개의 retrieved blocks (본 실험에서는  $k=5$ )

$$P(b, s|q) = \frac{\exp(S(b, s, q))}{\sum_{b' \in TOP(k)} \sum_{s' \in b'} \exp(S(b', s', q))}$$

- loss
  - 정답  $a$ 가 주어지면 가능한 공간에서 모든 예측 문장을 찾고 출력한 top- $k$ 에 대해 log-likelihood로 최적화
  - retriever로 검색한 top  $k$ 개 block  $b$  내의 span 중 문자열로 변환 시 정답  $a$ 가 되는 span의 확률값  $P'$

$$L_{full}(q, a) = -\log \sum_{b \in TOP(k)} \sum_{s \in b, a=TEXT(s)} P'(b, s|q)$$

## Early Learning

- 학습을 위해 많은 evidence block을 고려하되 계산 비용이 저렴한 score만 업데이트한다.
- top k보다 큰 c개

$$P_{\text{early}}(b|q) = \frac{\exp(S_{\text{retr}}(b, q))}{\sum_{b' \in \text{TOP}(c)} \exp(S_{\text{retr}}(b', q))}$$
$$L_{\text{early}}(q, a) = -\log \sum_{b \in \text{TOP}(c), a \in \text{TEXT}(b)} P_{\text{early}}(b|q)$$

## 최종 Loss

$$L(q, a) = L_{\text{early}}(q, a) + L_{\text{full}}(q, a)$$

Evidence block encoder를 제외하고 모든 파라미터를 fine-tuning함  
Query encoder는 학습 가능하므로 ORQA모델이 어떤 evidence block을 가져올지 학습 가능

➡ 단지 evidence 수를 늘려 성능을 개선하는 IR system과 중요한 차이점

## Natural Questions

- Google search로 집계된 질문 포함
- 답변이 말뭉치에서 추출된 형태와 가까워 5개의 토큰 이상의 답변은 버림 (짧은 답변만 취함)
  - “1+1은 몇인가” 라는 질문에 “안녕하세요, 제가 수학문제를 참 잘 푸는데요. 답은 아마도 2인것 같습니다. ...” 보다는 “2”를 채택함

## Web Questions

- Google Suggest API에서 얻은 QA 데이터
- 단답형 답변

## Created Tree

- TREC QA 데이터에서 파생된 QA 말뭉치
- 실제 쿼리 소스들로부터 질문 얻음

## Trivia QA

- 웹에서 얻은 trivia question-answering 쌍 모음
- 필터링 없이 사용, 답변시 외부자료를 링크하거나 참고하는 부분은 삭제

## SQuAD

- ODQA를 위함이기 보단 독해를 위해 설계됨
- Wikipedia 문단에서 정답 범위를 지정, 지문에 있는 답으로 답변 가능한 질문

## Natural Question / Web Question / Curated Trec

|      | Model             | BM25<br>+BERT | NNLM<br>+BERT | ELMo<br>+BERT | ORQA        |
|------|-------------------|---------------|---------------|---------------|-------------|
| Dev  | Natural Questions | 24.8          | 3.2           | 3.6           | <b>31.3</b> |
|      | WebQuestions      | 20.8          | 9.1           | 17.7          | <b>38.5</b> |
|      | CuratedTrec       | 27.1          | 6.0           | 8.3           | <b>36.8</b> |
|      | TriviaQA          | <b>47.2</b>   | 7.3           | 6.0           | 45.1        |
|      | SQuAD             | <b>28.1</b>   | 2.8           | 1.9           | 26.5        |
| Test | Natural Questions | 26.5          | 4.0           | 4.7           | <b>33.3</b> |
|      | WebQuestions      | 17.7          | 7.3           | 15.6          | <b>36.4</b> |
|      | CuratedTrec       | 21.3          | 4.5           | 6.8           | <b>30.1</b> |
|      | TriviaQA          | <b>47.1</b>   | 7.1           | 5.7           | 45.0        |
|      | SQuAD             | <b>33.2</b>   | 3.2           | 2.3           | 20.2        |

- 질문자가 답을 알지 못함
- **ORQA**에서 성능이 우수

Table 5: **Main results:** End-to-end exact match for open-domain question answering from question-answer pairs only. Datasets where question askers know the answer behave differently from datasets where they do not.

ICT 사전학습 batch size = 4096

fine-tuning batch size = 1

fine-tuning시 large dataset(NQ, TriviaQA, SQuAD)은 2 epoch 학습

fine-tuning시 small dataset(WebQ, CuratedTrec)은 20 epoch 학습

Top k = 5개

평가 : Exact Match



## TriviaQA / SQuAD

|      | Model             | BM25<br>+BERT | NNLM<br>+BERT | ELMo<br>+BERT | ORQA        |
|------|-------------------|---------------|---------------|---------------|-------------|
| Dev  | Natural Questions | 24.8          | 3.2           | 3.6           | <b>31.3</b> |
|      | WebQuestions      | 20.8          | 9.1           | 17.7          | <b>38.5</b> |
|      | CuratedTrec       | 27.1          | 6.0           | 8.3           | <b>36.8</b> |
|      | TriviaQA          | <b>47.2</b>   | 7.3           | 6.0           | 45.1        |
|      | SQuAD             | <b>28.1</b>   | 2.8           | 1.9           | 26.5        |
| Test | Natural Questions | 26.5          | 4.0           | 4.7           | <b>33.3</b> |
|      | WebQuestions      | 17.7          | 7.3           | 15.6          | <b>36.4</b> |
|      | CuratedTrec       | 21.3          | 4.5           | 6.8           | <b>30.1</b> |
|      | TriviaQA          | <b>47.1</b>   | 7.1           | 5.7           | 45.0        |
|      | SQuAD             | <b>33.2</b>   | 3.2           | 2.3           | 20.2        |

Table 5: **Main results:** End-to-end exact match for open-domain question answering from question-answer pairs only. Datasets where question askers know the answer behave differently from datasets where they do not.

- BM25에 적합한 dataset
  - TF - IDF로 구성된 정답과 answer가 둘 다 존재
    - ( 답을 알고 있음 )
  - 검색 문제가 기존 IR과 유사함
- **BM25에서 성능이 우수**
- ORQA에서는 성능이 좋지 않음

ICT 사전학습 batch size = 4096

fine-tuning batch size = 1


fine-tuning시 large dataset(NQ, TriviaQA, SQuAD)은 2 epoch 학습

fine-tuning시 small dataset(WebQ, CuratedTrec)은 20 epoch 학습

Top k = 5개

평가 : Exact Match

- retriever가 word matching이 불가능하도록 하고싶은 것은 아님
- word - matching이 가능하도록 ICT masking의 각 비율을 실험
  - Semantic information (90%) / word matching information (10%)
    - Wikipedia에서 90%는 ICT의 block에서 question을 선택한 후 masking 처리
    - 나머지 10%는 ICT의 block에서 question을 선택한 후 masking 처리를하지 않고 question이 있는 그대로 이용함



| Example                                                                                       | ORQA                                                                                                                                                                                                                             | BM25 + BERT                                                                                                                                                                                                                      |
|-----------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Q: what is the new orleans saints symbol called<br>A: fleur-de-lis                            | ...The team's primary colors are old gold and black; their logo is a simplified <b>fleur-de-lis</b> . They played their home games in Tulane Stadium through the 1974 NFL season....                                             | ...the <b>SkyDome</b> was owned by Sportsco at the time... the sale of the New Orleans Saints with team owner Tom Benson... the Saints became a symbol for that community...                                                     |
| Q: how many senators per state in the us<br>A: two                                            | ...powers of the Senate are established in Article One of the U.S. Constitution. Each U.S. state is represented by <b>two</b> senators...                                                                                        | ...The Georgia Constitution mandates a maximum of <b>56</b> senators, elected from single-member districts...                                                                                                                    |
| Q: when was germany given a permanent seat on the council of the league of nations<br>A: 1926 | ...Under the Weimar Republic, Germany (in fact the "Deutsches Reich" or German Empire) was admitted to the League of Nations through a resolution passed on September 8 <b>1926</b> . An additional 15 countries joined later... | ...the accession of the German Democratic Republic to the Federal Republic of Germany, it was effective on <b>3 October 1990</b> ...Germany has been elected as a non-permanent member of the United Nations Security Council... |
| Q: when was diary of a wimpy kid double down published<br>A: November 1, 2016                 | ...“Diary of a Wimpy Kid” first appeared on FunBrain in 2004, where it was read 20 million times. The abridged hardcover adaptation was released on <b>April 1, 2007</b> ...                                                     | Diary of a Wimpy Kid: Double Down is the eleventh book in the "Diary of a Wimpy Kid" series by Jeff Kinney... The book was published on <b>November 1, 2016</b> ...                                                              |

Table 7: **Analysis:** Example predictions on our open version of the Natural Questions dev set. We show the highest scoring derivation, consisting of the evidence block and the predicted answer in bold. ORQA is more robust at separating semantically distinct text that have high lexical overlap. However, the limitation of the 128-dimensional vectors is that extremely specific concepts are less precisely represented.

- 어휘 중복이 많은 텍스트를 분리하는데 강력
- 그러나 **128차원 벡터로 압축할 수 있는 정보의 양에는 한계가 있음**
- 정보량이 적어서 검색이 잘 안되는 경우도 있음

**IR system 없이 question-answer 쌍을 이용해 retrieval와 reader가 end-to-end 학습을 하는 최초의 open domain question answering system인 ORQA**

- Open Domain QA에서 IR system은 최적이지 아닐 수 있다.
  - 정답이 항상 주어지는 것이 아님
  - QA와 IR은 다름
- Retriever와 Reader가 함께 end-to-end 학습이 가능하도록 하는 방법
  - Inverse Cloze Task를 이용한 Retriever 사전학습 적용
- Retriever를 학습시키는 것은 현실적인 QA task (질문자가 정답을 모르고 만들어진, 진짜 정보를 찾고자 하는 의도가 있을 때)에 있어서 중요하다.



**Making the Great! Making the New**

**감사합니다**