

M3-Embeddig: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation

Songwon Park

xlah1386@gs.cwnu.ac.kr

2025. 06. 12

M3-Embeddig: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation


- **Jianlv Chen and Shitao Xiao and Peitian Zhang and Kun Luo and Defu Lian and Zheng Liu**

(BAAI, University of Science and Technology of China)

- **ACL 2024**
- [paper](#)

메인 아이디어

Multi-Linguality, Multi-Functionality, Multi-Granularity를 만족하는 임베딩 모델



- Multi - Linguality (다국어)
 - 100개 이상의 언어 지원, 다른 언어 간 교차 검색 가능
- Multi - Functionality (다기능)
 - Dense retrieval 뿐만 아니라 sparse, multi-vector retrieval 지원
- Multi - Granularity (다세분성)
 - 최대 토큰 길이 8192까지 처리 가능

임베딩 모델

- IR(Information Retrieval)에 사용되는 임베딩 모델은 많은 연구가 됨
- 사전학습 된 언어 모델의 등장으로 임베딩 품질이 향상되어 정보검색의 필수 요소
- 기존 방법들의 한계점
 1. 임베딩 모델은 영어에만 맞춰져 있어 다른 언어에 적용 가능한 옵션이 거의 없음
 2. 일반적 검색 시스템은 여러 검색 방법을 사용해 복잡하지만 기존 임베딩 모델은 단일 검색 기능에 대해 학습
 3. 대부분 임베딩은 짧은 입력만 지원해 장문 문서 학습이 어려움

- 임베딩 모델의 주요 응용 분야 => 신경망 검색
 - 텍스트 임베딩과 의미적 관계를 측정하며 임베딩 유사도를 기반으로 질의에 대한 답변 검색
- **Dense Retrieval**
 - 텍스트 인코더의 출력을 모아 임베딩 유사도를 계산하여 관련 답변 검색
 - ex) [CLS] 토큰 또는 평균 pooling
- **Multi-vector Retrieval**
 - 여러 임베딩의 상호 점수를 기반으로 쿼리와 문서 간 유사도를 계산하여 관련 답변 검색
- **Sparse or Lexical Retrieval**
 - 텍스트 임베딩을 변환하여 만든 용어 가중치를 이용해 검색



세 기능을 통합할 수 있는 기존 방법이 없음

M3-Embedding

- 다양한 언어 지원
- 다양한 단위의 입력 데이터 처리 가능
- 텍스트 임베딩의 세 검색 기능 통합

$$D^y : d^y \leftarrow f_n(q^x, D^y)$$

- 임의의 언어 x, y
- D^y : y 언어로 작성된 코퍼스
- d^y : y 언어로 작성된 문서
- f_n : dense, lexical, multi-vector 중 하나

➡ 임의의 언어 x 로 작성된 쿼리 q 가 주어졌을 때, D^y 코퍼스에서 언어 y 로 작성된 문서 d 검색 가능

Dense Retrieval

- [CLS] 토큰의 정규화된 hidden state 이용해 임베딩 계산
- query와 passage간 유사도 점수는 두 임베딩의 내적으로 계산

$$e_q = \text{norm}(H_q[0]) \quad e_p = \text{norm}(H_p[0])$$

- H_q, H_p : 인코더를 통해 변환된 hidden state
- $H[0]$: [CLS] 토큰의 hidden state
- norm : 정규화

$$s_{dense} = \langle e_p, e_q \rangle$$

Lexical Retrieval

- query 내 각 용어에 대한 가중치와 passage 내 용어 가중치를 계산
- query와 passage에 함께 존재하는 용어($t \in q \cap p$)의 가중치를 이용해 유사도 계산
- 용어 t 가 쿼리 내 여러번 나타나는 경우 최대 가중치만 유지

$$w_{q_t} \leftarrow \text{Relu}(W_{lex}^T H_q[i]) \quad , \text{ when } W_{lex} \in \mathcal{R}^{d \times 1}$$

$$s_{lex} \leftarrow \sum_{t \in q \cap p} (w_{q_t} * w_{p_t})$$

- $W_{lex} \in \mathcal{R}^{d \times 1}$: 토큰의 중요도 가중치를 계산하기 위한 학습 가능한 매개변수 행렬
- $t \in q \cap p$: query와 passage 내 함께 존재하는 용어

Multi - vector Retrieval

- Dense retrieval의 확장
- [CLS] 토큰을 제외한 query와 passage의 전체 임베딩을 사용
- Late interaction(후기 상호작용)을 이용해 유사도 계산
 - query의 각 토큰 임베딩과 passage의 모든 토큰 임베딩 간 유사도를 계산한 뒤 query 토큰별 가장 높은 유사도 선택한 후 최대값들의 합의 평균을 최종 유사도 점수로 이용

$$E_q = \text{norm}(W_{mul}^T H_q) \quad E_p = \text{norm}(W_{mul}^T H_p) \quad , \text{ when } W_{mul} \in \mathbb{R}^{d \times d}$$

$$s_{mul} \leftarrow \frac{1}{N} \sum_{i=1}^N \max_{j=1}^M E_q[i] \cdot E_p^T[j]$$

- $W_{mul} \in \mathbb{R}^{d \times d}$: 학습 가능한 투영 행렬
- N, M : query와 passage 길이

With Self-knowledge distillation

- Dense retrieval, lexical retrieval, multi-vector retrieval을 통합적으로 학습하기 위해 도입
- 각 점수의 가중합계를 이용해 통합 점수 s_{inter} 계산

$$s_{inter} \leftarrow w_1 \cdot s_{dense} + w_2 \cdot s_{lex} + w_3 \cdot s_{mul}$$

- 통합 점수 s_{inter} 를 교사로 사용하여 loss 계산

$$L'_* \leftarrow p(s_{inter} * \log p(s_*))$$

- $p(\cdot)$: softmax 함수

- s_* : s_{dense} , s_{lex} , s_{mul} 중 하나

$$L' \leftarrow (\lambda_1 \cdot L'_{dense} + \lambda_2 \cdot L'_{lex} + \lambda_3 \cdot L'_{mul}) / 3$$

Without Self-knowledge distillation

- negative 샘플보다 positive 샘플에 더 높은 점수를 부여하는 InfoNCE loss 이용
- InfoNCE loss를 최소화하도록 학습

$$L_s = -\log \frac{\exp(s(q, p^*)/\tau)}{\sum_{p \in \{p^*, P\}} \exp(s(q, p)/\tau)}$$

- p^* : query q 에 대한 positive 샘플
- P' : query q 에 대한 negative 샘플
- $s(\cdot)$: $s_{dense}(\cdot)$, $s_{lex}(\cdot)$, $s_{mul}(\cdot)$ 중 하나

- L_{dense} , L_{lex} , L_{mul} , L_{inter} 가중합을 계산하여 평균

$$L \leftarrow (\lambda_1 \cdot L_{dense} + \lambda_2 \cdot L_{lex} + \lambda_3 \cdot L_{mul} + L_{inter}) / 4$$

Final loss

- Self-knowledge distillation을 사용한 loss L'
- Self-knowledge distillation을 사용하지 않은 loss L

➡ 두 loss의 평균을 최종 loss로 이용

$$L_{final} = \frac{L + L'}{2}$$




Figure 2: **Multi-stage training process of M3-Embedding with self-knowledge distillation.**

- **Pre-trained**
 - Unsupervised data로 사전학습 진행
 - Dense retrieval만 대조학습의 형태로 학습
- **Fine-tuning**
 - Supervised data와 Synthetic data(합성 데이터)로 세 가지 검색을 이용해 fine-tuning
 - Self-knowledge distillation 적용

Efficient Batching




Figure 3: **Efficient Batching.** (Data is grouped and sampled by length. Gradient-checkpointing and cross-GPU broadcasting are enabled to save memory.)

- 다양한 길이의 입력을 효율적으로 처리하기 위한 방법
- 시퀀스 길이 별로 그룹화되어 전처리
 - 시퀀스 길이가 유사하기 때문에 padding 사용 최소화
- 동일 그룹 내에서 미니 배치 샘플링
- 데이터 리소스가 제한적인 사용자를 위해 더 간단한 MCLS(Multi-CLS) 방법 추가 제시
 - 긴 문서에 여러 개의 [CLS] 토큰을 삽입하고, 모든 CLS 임베딩의 평균을 문서의 최종 임베딩으로 사용

- **Unsupervised data** (비지도 데이터)
 - 레이블 없는 다국어 코퍼스에서 제목-본문, 제목-초록 등과같은 유의미한 텍스트 쌍 추출
- **Supervised data** (지도 데이터)
 - 라벨링된 코퍼스로부터 작지만 다양한 fine-tuning 데이터 수집
 - TriviaQA, MS MARCO, SQuAD 등과 같은 데이터셋 이용
- **Synthetic Data** (합성 데이터)
 - 장문 문서 검색 부족을 완화하고 추가적 다국어 fine-tuning을 위한 합성 데이터 생성
 - 위키백과 등의 데이터셋에서 장문 문서를 샘플링하고 무작위로 단락 선택
 - GPT3.5를 이용해 선택한 단락을 기반으로 질문 생성

Model	Avg	ar	bn	en	es	fa	fi	fr	hi	id	ja	ko	ru	sw	te	th	zh	de	yo
Baselines (<i>Prior Work</i>)																			
BM25	31.9	39.5	48.2	26.7	7.7	28.7	45.8	11.5	35.0	29.7	31.2	37.1	25.6	35.1	38.3	49.1	17.5	12.0	56.1
mDPR	41.8	49.9	44.3	39.4	47.8	48.0	47.2	43.5	38.3	27.2	43.9	41.9	40.7	29.9	35.6	35.8	51.2	49.0	39.6
mContriever	43.1	52.5	50.1	36.4	41.8	21.5	60.2	31.4	28.6	39.2	42.4	48.3	39.1	56.0	52.8	51.7	41.0	40.8	41.5
mE5 _{large}	66.6	76.0	75.9	52.9	52.9	59.0	77.8	54.5	62.0	52.9	70.6	66.5	67.4	74.9	84.6	80.2	56.0	56.4	78.3
E5 _{mistral-7b}	63.4	73.3	70.3	57.3	52.2	52.1	74.7	55.2	52.1	52.7	66.8	61.8	67.7	68.4	73.9	74.0	54.0	54.1	79.7
OpenAI-3	54.9	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-
M3-Embedding (<i>Our Work</i>)																			
Dense	69.2	78.4	80.0	56.9	56.1	60.9	78.6	58.3	59.5	56.1	72.8	69.9	70.1	78.7	86.2	82.6	62.7	56.7	81.8
Sparse	53.9	67.1	68.9	43.8	38.6	45.1	65.4	35.3	48.2	48.9	56.1	61.5	44.5	57.9	79.1	70.9	36.1	32.5	70.0
Multi-vec	70.5	79.6	81.0	59.3	57.8	62.0	80.1	59.4	61.5	58.3	74.5	71.2	71.2	79.1	87.9	83.0	63.7	58.0	82.4
Dense+Sparse	70.4	79.6	80.7	58.8	58.1	62.3	79.7	58.0	62.9	58.3	73.9	71.2	69.8	78.5	87.2	83.1	63.5	57.7	83.3
All	71.5	80.2	81.5	59.6	59.7	63.4	80.4	61.2	63.3	59.0	75.2	72.1	71.7	79.6	88.1	83.7	64.9	59.8	83.5

Table 1: Multi-lingual retrieval performance on the MIRACL dev set (measured by nDCG@10).

- M3-Embedding은 dense 검색만으로도 우수한 성능 달성
 - Mistral-7B을 인코더로 활용하고 영어로 학습한 E5 mistral-7b와 비교해도 영어에서 유사, 다른 언어에서는 높은 결과를 보임
- M3-Embedding sparse 검색은 모든 언어에서 BM25보다 우수한 성능을 보임

1. nDCG@n (Normalized Discounted Cumulative Gain)

: 정보검색 및 추천 시스템에서 랭킹 품질을 평가하는 지표, 상위 n개 결과의 순서와 관련성을 종합적으로 측정

2. MIRACL (Multilingual Information Retrieval Across a Continuum of Languages)

: 18개 언어를 지원하는 다국어 검색 벤치마크 데이터셋

3. E5 mistral-7b

: mistral-7b를 백본으로 활용, 다국어 검색 및 zero-shot 검색에 최적화됨

Model	Avg	ar	bn	en	es	fa	fi	fr	hi	id	ja	ko	ru	sw	te	th	zh	de	yo
Baselines (<i>Prior Work</i>)																			
BM25	31.9	39.5	48.2	26.7	7.7	28.7	45.8	11.5	35.0	29.7	31.2	37.1	25.6	35.1	38.3	49.1	17.5	12.0	56.1
mDPR	41.8	49.9	44.3	39.4	47.8	48.0	47.2	43.5	38.3	27.2	43.9	41.9	40.7	29.9	35.6	35.8	51.2	49.0	39.6
mContriever	43.1	52.5	50.1	36.4	41.8	21.5	60.2	31.4	28.6	39.2	42.4	48.3	39.1	56.0	52.8	51.7	41.0	40.8	41.5
mE5 _{large}	66.6	76.0	75.9	52.9	52.9	59.0	77.8	54.5	62.0	52.9	70.6	66.5	67.4	74.9	84.6	80.2	56.0	56.4	78.3
E5 _{mistral-7b}	63.4	73.3	70.3	57.3	52.2	52.1	74.7	55.2	52.1	52.7	66.8	61.8	67.7	68.4	73.9	74.0	54.0	54.1	79.7
OpenAI-3	54.9	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-
M3-Embedding (<i>Our Work</i>)																			
Dense	69.2	78.4	80.0	56.9	56.1	60.9	78.6	58.3	59.5	56.1	72.8	69.9	70.1	78.7	86.2	82.6	62.7	56.7	81.8
Sparse	53.9	67.1	68.9	43.8	38.6	45.1	65.4	35.3	48.2	48.9	56.1	61.5	44.5	57.9	79.1	70.9	36.1	32.5	70.0
Multi-vec	70.5	79.6	81.0	59.3	57.8	62.0	80.1	59.4	61.5	58.3	74.5	71.2	71.2	79.1	87.9	83.0	63.7	58.0	82.4
Dense+Sparse	70.4	79.6	80.7	58.8	58.1	62.3	79.7	58.0	62.9	58.3	73.9	71.2	69.8	78.5	87.2	83.1	63.5	57.7	83.3
All	71.5	80.2	81.5	59.6	59.7	63.4	80.4	61.2	63.3	59.0	75.2	72.1	71.7	79.6	88.1	83.7	64.9	59.8	83.5

Table 1: Multi-lingual retrieval performance on the MIRACL dev set (measured by nDCG@10).

- Dense + sparse 검색은 각각의 방법보다 향상된 성능을 보임
- Dense + sparse + multi-vector 검색은 가장 좋은 성능을 보임

	Baselines (Prior Work)						M3-Embedding (Our Work)				
	BM25	mDPR	mContriever	mE5 _{large}	E5 _{mistral-7b}	OpenAI-3	Dense	Sparse	Multi-vec	Dense+Sparse	All
ar	18.9	48.2	58.2	68.7	59.6	65.6	71.1	23.5	71.4	71.1	71.5
da	49.3	67.4	73.9	77.4	77.8	73.6	77.2	55.4	77.5	77.4	77.6
de	35.4	65.8	71.7	76.9	77.0	73.6	76.2	43.3	76.3	76.4	76.3
es	43.4	66.8	72.6	76.4	77.4	73.9	76.4	50.6	76.6	76.7	76.9
fi	46.3	56.2	70.2	74.0	72.0	72.7	75.1	51.1	75.3	75.3	75.5
fr	45.3	68.2	72.8	75.5	78.0	74.1	76.2	53.9	76.4	76.6	76.6
he	26.9	49.7	63.8	69.6	47.2	58.1	72.4	31.1	72.9	72.5	73.0
hu	38.2	60.4	69.7	74.7	75.0	71.2	74.7	44.6	74.6	74.9	75.0
it	45.2	66.0	72.3	76.8	77.1	73.6	76.0	52.5	76.4	76.3	76.5
ja	24.5	60.3	64.8	71.5	65.1	71.9	75.0	31.3	75.1	75.0	75.2
km	27.8	29.5	26.8	28.1	34.3	33.9	68.6	30.1	69.1	68.8	69.2
ko	27.9	50.9	59.7	68.1	59.4	63.9	71.6	31.4	71.7	71.6	71.8
ms	55.9	65.5	74.1	76.3	77.2	73.3	77.2	62.4	77.4	77.4	77.4
nl	56.2	68.2	73.7	77.8	79.1	74.2	77.4	62.4	77.6	77.7	77.6
no	52.1	66.7	73.5	77.3	76.6	73.3	77.1	57.9	77.2	77.4	77.3
pl	40.8	63.3	71.6	76.7	77.1	72.7	76.3	46.1	76.5	76.3	76.6
pt	44.9	65.5	72.0	73.5	77.5	73.7	76.3	50.9	76.4	76.5	76.4
ru	33.2	62.7	69.8	76.8	75.5	72.0	76.2	36.9	76.4	76.2	76.5
sv	54.6	66.9	73.2	77.6	78.3	74.0	76.9	59.6	77.2	77.4	77.4
th	37.8	53.8	66.9	76.0	67.4	65.2	76.4	42.0	76.5	76.5	76.6
tr	45.8	59.1	71.1	74.3	73.0	71.8	75.6	51.8	75.9	76.0	76.0
vi	46.6	63.4	70.9	75.4	70.9	71.1	76.6	51.8	76.7	76.8	76.9
zh.cn	31.0	63.7	68.1	56.6	69.3	70.7	74.6	35.4	74.9	74.7	75.0
zh.hk	35.0	62.8	68.0	58.1	65.1	69.6	73.8	39.8	74.1	74.0	74.3
zh.tw	33.5	64.0	67.9	58.1	65.8	69.7	73.5	37.7	73.5	73.6	73.6
Avg	39.9	60.6	67.9	70.9	70.1	69.5	75.1	45.3	75.3	75.3	75.5

Table 2: Cross-lingual retrieval performance on MKQA (measured by Recall@100).

- Dense retrieval 만으로도 우수한 성능
- E5 mistral-7b의 경우 일부 언어에서 우수한 성능을 보이지만, M3-Embedding은 모든 언어에서 안정적인 성능 유지
- M3-Embedding sparse의 경우 query와 passage가 다른 언어로 구성되어 함께 존재하는 용어가 제한적이라 성능이 다소 떨어짐

	Max Length	Avg	ar	de	en	es	fr	hi	it	ja	ko	pt	ru	th	zh
Baselines (<i>Prior Work</i>)															
BM25	8192	53.6	45.1	52.6	57.0	78.0	75.7	43.7	70.9	36.2	25.7	82.6	61.3	33.6	34.6
mDPR	512	23.5	15.6	17.1	23.9	34.1	39.6	14.6	35.4	23.7	16.5	43.3	28.8	3.4	9.5
mContriever	512	31.0	25.4	24.2	28.7	44.6	50.3	17.2	43.2	27.3	23.6	56.6	37.7	9.0	15.3
mE5 _{large}	512	34.2	33.0	26.9	33.0	51.1	49.5	21.0	43.1	29.9	27.1	58.7	42.4	15.9	13.2
E5 _{mistral-7b}	8192	42.6	29.6	40.6	43.3	70.2	60.5	23.2	55.3	41.6	32.7	69.5	52.4	18.2	16.8
text-embedding-ada-002	8191	32.5	16.3	34.4	38.7	59.8	53.9	8.0	46.5	28.6	20.7	60.6	34.8	9.0	11.2
jina-embeddings-v2-base-en	8192	-	-	-	37.0	-	-	-	-	-	-	-	-	-	-
M3-Embedding (<i>Our Work</i>)															
Dense	8192	52.5	47.6	46.1	48.9	74.8	73.8	40.7	62.7	50.9	42.9	74.4	59.5	33.6	26.0
Sparse	8192	62.2	58.7	53.0	62.1	87.4	82.7	49.6	74.7	53.9	47.9	85.2	72.9	40.3	40.5
Multi-vec	8192	57.6	56.6	50.4	55.8	79.5	77.2	46.6	66.8	52.8	48.8	77.5	64.2	39.4	32.7
Dense+Sparse	8192	64.8	63.0	56.4	64.2	88.7	84.2	52.3	75.8	58.5	53.1	86.0	75.6	42.9	42.0
All	8192	65.0	64.7	57.9	63.8	86.8	83.9	52.2	75.5	60.1	55.7	85.4	73.8	44.7	40.0
M3-w.o.long															
Dense-w.o.long	8192	41.2	35.4	35.2	37.5	64.0	59.3	28.8	53.1	41.7	29.8	63.5	51.1	19.5	16.5
Dense-w.o.long (MCLS)	8192	45.0	37.9	43.3	41.2	67.7	64.6	32.0	55.8	43.4	33.1	67.8	52.8	27.2	18.2

Table 3: Evaluation of multilingual long-doc retrieval on the MLDR test set (measured by nDCG@10).

- 긴 문서 검색에 좋은 성능을 보이는 JinaEmbeddingv2, text-embedding-ada-002도 추가로 비교
- M3-Embedding sparse는 M3-Embedding dense에 비해 긴 문서 검색에 우수한 성능을 보임
- 세 검색 방법을 조합한 방법의 평균이 가장 우수

	Max Length	Avg	ar	de	en	es	fr	hi	it	ja	ko	pt	ru	th	zh
Baselines (<i>Prior Work</i>)															
BM25	8192	53.6	45.1	52.6	57.0	78.0	75.7	43.7	70.9	36.2	25.7	82.6	61.3	33.6	34.6
mDPR	512	23.5	15.6	17.1	23.9	34.1	39.6	14.6	35.4	23.7	16.5	43.3	28.8	3.4	9.5
mContriever	512	31.0	25.4	24.2	28.7	44.6	50.3	17.2	43.2	27.3	23.6	56.6	37.7	9.0	15.3
mE5 _{large}	512	34.2	33.0	26.9	33.0	51.1	49.5	21.0	43.1	29.9	27.1	58.7	42.4	15.9	13.2
E5 _{mistral-7b}	8192	42.6	29.6	40.6	43.3	70.2	60.5	23.2	55.3	41.6	32.7	69.5	52.4	18.2	16.8
text-embedding-ada-002	8191	32.5	16.3	34.4	38.7	59.8	53.9	8.0	46.5	28.6	20.7	60.6	34.8	9.0	11.2
jina-embeddings-v2-base-en	8192	-	-	-	37.0	-	-	-	-	-	-	-	-	-	-
M3-Embedding (<i>Our Work</i>)															
Dense	8192	52.5	47.6	46.1	48.9	74.8	73.8	40.7	62.7	50.9	42.9	74.4	59.5	33.6	26.0
Sparse	8192	62.2	58.7	53.0	62.1	87.4	82.7	49.6	74.7	53.9	47.9	85.2	72.9	40.3	40.5
Multi-vec	8192	57.6	56.6	50.4	55.8	79.5	77.2	46.6	66.8	52.8	48.8	77.5	64.2	39.4	32.7
Dense+Sparse	8192	64.8	63.0	56.4	64.2	88.7	84.2	52.3	75.8	58.5	53.1	86.0	75.6	42.9	42.0
All	8192	65.0	64.7	57.9	63.8	86.8	83.9	52.2	75.5	60.1	55.7	85.4	73.8	44.7	40.0
M3-w.o.long															
Dense-w.o.long	8192	41.2	35.4	35.2	37.5	64.0	59.3	28.8	53.1	41.7	29.8	63.5	51.1	19.5	16.5
Dense-w.o.long (MCLS)	8192	45.0	37.9	43.3	41.2	67.7	64.6	32.0	55.8	43.4	33.1	67.8	52.8	27.2	18.2

Table 3: Evaluation of multilingual long-doc retrieval on the MLDR test set (measured by nDCG@10).

- w.o.long : fine-tuning 단계에서 긴 문서 데이터를 제거한 것
 - 대부분의 dense baseline보다 우수한 성능을 보임
 - MCLS(Multi-CLS) 이용시 학습 없이도 문서 검색 성능 향상시킬 수 있음을 입증 (41.2 -> 45.0)

- M3-Embedding
 - 다국어 검색, 교차 언어 검색, 다국어 장문 문서 검색 작업에서 우수한 성능을 보임
- 다국어 및 교차 언어 벤치마크에서 최고 수준의 성능을 달성하지만, 다양한 데이터셋에 대한 접근 방식의 일반화 가능성에 대한 추가 연구가 필요
- 매우 긴 문서를 처리하는 것은 모델 효율성 측면에서 어려울 수 있음. 지정된 토큰 길이를 초과하는 문서에 대한 성능은 추가 연구 필요
- 100개 이상이 언어를 지원한다고 주장하지만, 언어 간 성능 차이에 대한 추후 연구 필요



Making the Great! Making the New

감사합니다