

Unsupervised Dense Information Retrieval with Contrastive Learning

Songwon Park

xlah1386@gs.cwnu.ac.kr

2025. 12. 11

Unsupervised Dense Information Retrieval with Contrastive Learning

- **Gautier Izacard and Mathilde Caron and Lucas Hosseini and Sebastian Riedel and Piotr Bojanowski and Armand Joulin and Edouard Grave**

(Meta AI Research)

- **arXiv 2021**

- [paper](#)

메인 아이디어

unsupervised 데이터셋을 cropping과 MoCo를 이용해 샘플링 후 dense retriever를
대조학습으로 사전학습 진행

- 최근 정보검색분야에서는 용어 빈도에 기반한 전통적인 sparse retriever의 대안으로 신경망을 사용하는 dense retriever가 등장
 - 대규모 학습 데이터셋이 제공되는 데이터셋과 태스크에서 최첨단 성능을 달성
 - 그러나 학습데이터가 존재하지 않는 경우 성능이 잘 나오지 않고, BM25와 같은 용어 빈도 기반 방법들보다 성능이 떨어지는 문제 존재



- 본 논문에서는 라벨이 없는 대규모 데이터셋을 cropping과 MoCo 기반 샘플링으로 구성한 후 대조학습으로 dense retriever를 사전학습하는 방법 제안
- BEIR 벤치마크에서 Recall@100 기준 15개 데이터셋 중 11개에서 BM25보다 뛰어난 성능을 보임
- 사전학습한 제안모델을 fine-tuning하는 경우 BEIR 벤치마크에서 추가적인 성능 향상을 보임

- 문서 검색은 질의에 답하기 위해 대규모 문서 컬렉션에서 관련 문서들을 찾는 작업
- TF-IDF, BM25와 같은 전통적인 `sparse retrieval`은 질의와 문서 사이의 어휘 유사성을 활용해 매칭 수행
- 질의와 문서에 포함된 토큰들 사이의 일치에 의존하기 때문에 의미적 매칭 문제를 겪으며 일반화가 어렵다는 단점이 존재
- `dense retrieval`의 등장으로 의미적 매칭을 가능하게 하며 MS MARCO와 같은 질의응답 벤치마크에서 높은 성능 달성
- `dense retrieval`의 높은 성능은 대규모 학습 데이터셋이 존재하는 도메인에 한해서 가능
 - 대규모 학습 데이터셋을 만들기 위해서는 질의와 컬렉션 안의 문서들을 수작업으로 일치 시켜야해서 거의 불가능함
- 해결책은 MS MARCO와 같은 대규모 검색 데이터셋으로 학습한 후 새로운 도메인에 적용하는 것
 - 이 방법은 용어 빈도 기반을 이용한 전통적인 `sparse retrieval` 방법에 비해 자주 성능이 떨어지는 문제

→ 대규모 supervised data에 의존하는 방법은 적합하지 않다고 판단

Unsupervised 데이터를 이용한 학습

- 전이학습에 대한 대안은 unsupervised data를 이용한 학습
- supervised data 없이 학습하기 위해서는 보조적인 방법이 필요
 - 문서가 주어졌을 때 합성 질의를 생성하고, 그 질의를 이용해 원래 문서를 찾아내도록 학습
 - 주어진 문서의 일부분을 질의로 사용하고, 주변 문맥을 예측하도록 학습하는 Inverse Cloze Task(ICT)
 - ICT를 이용해 대조학습을 진행한 모델은 좋은 결과를 보였음에도 BM25와 비교했을 때 zero-shot retriever로서 성능차이를 해소하지 못함

→ 본 논문에서는 대조학습의 성능이 어느 정도까지 나올 수 있는지 확인할 것을 제안

Contributions

- 대조학습이 강력한 **unsupervised retriever**를 만들 수 있음을 증명
 - 제안 모델은 BEIR 벤치마크의 대부분 데이터셋에서 Recall@100 기준 BM25와 유사한 결과 달성
- **few-shot** 설정으로 제안 모델이 적은 학습 예제로부터 좋은 성능을 낼 수 있음을 증명
 - MS MARCO와 같은 대규모 데이터셋에서 학습한 모델을 단순히 전이하는 것보다 더 좋은 결과를 보임
- MS MARCO에서 **fine-tuning** 전에 사전학습 단계로 제안 기법을 사용할 경우, **BEIR 벤치마크**에서 강력한 성능 달성

- DPR (Dense Passage Retrieval)

- supervised dense retriever
- 질의와 문서를 각각의 임베딩으로 만드는 bi-encoder 기반
- 질의와 문서의 벡터를 내적해 유사도 계산
- 계산한 유사도를 이용해 대조학습 진행

$$\text{sim}(q, p) = E_Q(q)^T E_P(p)$$

- encoder : 두 개의 독립적인 BERT 사용 (출력 : [CLS] 토큰 (768차원))
 - $E_P(\cdot)$: passage를 벡터로 매핑하고 검색에 사용할 passage에 대한 인덱스를 구축하는 dense encoder
 - $E_Q(\cdot)$: 입력 질문을 벡터에 매핑하는 encoder
 - q, p : query, passage

$$L(q_i, p_i^+, p_{i,1}^-, \dots, p_{i,n}^-) = -\log \frac{e^{\text{sim}(q_i, p_i^+)}}{e^{\text{sim}(q_i, p_i^+)} + \sum_{j=1}^n e^{\text{sim}(q_i, p_{i,j}^-)}}$$

- q_i : query
- p_i^+ : positive passage
- $p_{i,j}^-$: negative passage

- **Positive and Negative passage**

- positive passage의 경우 데이터셋에 정의된 정답문서 사용
 - negative passage의 경우 선택의 폭이 매우 넓음
 - (1) Random : 코퍼스에서 랜덤 추출
 - (2) BM25 : BM25에서 반환된 상위 passage 중 답변은 없지만 질문의 토큰과 대부분 일치하는 passage (hard negative)
 - (3) Gold : 다른 질문의 positive passage
- ➡ 같은 미니배치 내 Gold + one BM25 negative passage가 성능이 가장 우수

- retriever 목표 : 주어진 질의에 대해 대규모 문서집합에서 관련 문서를 찾는 것
 - 질의와 문서 집합을 입력받아 질의와 각 문서에 대한 관련도 점수 출력
- 질의와 문서를 독립적으로 인코딩하는 bi-encoder 아키텍처를 이용해 얻어진 두 임베딩의 내적으로 관련도 점수 계산
 - 질의 q 와 문서 d 가 주어질 때, 모델 f_θ 를 이용하여 둘을 인코딩, 두 표현의 내적으로 관련도 점수 정의

$$s(q, d) = \langle f_\theta(q), f_\theta(d) \rangle$$

- q, d : 질의, 문서
- f_θ : 모델

Contrastive learning

- 대조학습은 “각 문서는 어떤 방식으로든 구분이 가능하다”는 사실에 의존하는 접근
- 비지도 학습에서 이러한 고유성이 유일한 정보
- 대조손실(contrastive loss)는 positive pair의 점수는 높게, negative pair의 점수는 낮게 만들도록 유도
- 질의 q 가 주어졌을 때, 목표는 K 개의 negative k_i 와 positive k^+ 문서 사이에서 올바른 key k^+ 를 검색한다고 볼 수 있음
 - 따라서 이후 관련도 점수 함수 $s(,)$ 의 왼쪽에 오는 표현을 queries, 오른쪽에 오는 표현들을 keys

$$L(q, k^+) = -\log \frac{\exp(s(q, k^+)/\tau)}{\exp(s(q, k^+)/\tau) + \sum_{i=1}^K \exp(s(q, k_i)/\tau)}$$

- $s(,)$: 관련도 점수 함수
- q : 질의
- k^+ : positive document
- τ : temperature 파라미터


Building positive pairs from a single document

- Inverse Cloze Task, ICT

- 문서에서 특정 span을 샘플링하여 질의로 사용하고, 해당 span을 제외한 나머지를 key로 사용하는 방법
- 토큰 $(t_1, \dots, t_n)$ 으로 이루어진 문서에서 $\text{span}(t_a, \dots, t_b)$ 를 샘플링하여 이 span을 질의로 사용하고, 해당 span을 제외한 $(t_1, \dots, t_{a-1}, t_{b+1}, \dots, t_n)$ 을 key로 사용
- lexical matching을 위해 10%의 확률로 질의 span을 문서 안에 남겨둠

원본 문서

...Zebras have four gaits: walk, trot, canter and gallop. They are generally slower than horses, but their great stamina helps them outrun predators. When chased, a zebra will zigzag from side to side ...



질의 span을 제외한 key

Building positive pairs from a single document

- Independent cropping

- 문서에서 질의로 사용할 span과 key(문서)로 사용할 span을 샘플링하는 방법
- ICT vs cropping
 - ICT의 경우 문서에서 하나의 span을 뽑아 질의로 사용하고, 해당 span을 제외한 모든 부분을 key로 사용함 → 연속적이지 않은 key를 가짐
 - cropping의 경우 질의와 key 모두 문서에서 span을 사용 → 연속적인 key를 가짐
 - 또한 span 길이가 어느정도 길다면 질의와 key가 겹쳐 둘 사이 exact matching이 가능해짐
- 본 논문의 경우 랜덤 cropping에 추가적으로 랜덤 단어 삭제, 단어 대체, 마스킹과 같은 방법도 함께 고려하여 사용됨

Building large set of negative pairs

- Negatives within a batch

- 동일 배치 내의 다른 쿼리들의 key들을 negative로 사용하는 방법 (In-batch negatives)
- gradient는 질의와 key 표현 모두를 통해 역전파됨
- 잘 작동하기 위해서는 매우 큰 배치 크기가 필요하다는 단점이 존재

- Building negative pairs across batches

- 이전 배치에서 계산된 표현들을 큐(queue)에 저장해두었다가 이들을 negative로 사용하는 방법
- gradient는 현재 배치 내에서 생성된 질의에 대해서만 역전파되고, 큐에 저장된 key 표현들은 고정된 값으로 취급된다.
 - 큐에 저장된 표현들은 모델 파라미터의 과거 상태에서 계산된 것
 - 학습 초기에 네트워크가 빠르게 변할 때는 성능이 떨어짐

Building large set of negative pairs

- MoCo (Momentum Contrast)

- 큐에 저장된 표현들은 모델 파라미터의 과거 상태에서 계산되어 학습 초기에 모델이 빠르게 변할 때는 성능이 떨어지는 것을 보완하기 위한 방법
- key 표현들을 생성하기 위한 두 번째 모델 도입, 이 모델을 더 느린 속도로 업데이트하는 방식 제안
- key를 위한 모델(파라미터 θ_k)과 질의를 위한 모델(파라미터 θ_q)을 고려
- 질의 모델은 in-batch negative를 사용할때와 유사하게 업데이트, key 모델은 질의 모델의 파라미터를 이용해 지수 이동 평균을 사용해 업데이트

$$\theta_k \leftarrow m\theta_k + (1 - m)\theta_q$$

지수 이동 평균 : 바로 직전 값보다 최근 값에 더 큰 가중치를 주어 점진적으로 값을 갱신하는 방식.
파라미터나 지표를 부드럽게 변화시키기 위해 사용

- θ_q : 질의 파라미터
- θ_d : key 파라미터
- m : $[0, 1]$ 범위의 값을 갖는 모멘텀 파라미터

setting

- positive pair는 random cropping을 이용해 샘플링하며, 쌍을 이루는 각 요소의 토큰은 10%의 확률로 삭제
- negative pair는 MoCo를 이용해 샘플링
- MoCo를 사용해 negative는 큐에 저장된 이전 배치의 요소들로 구성
 - 이를 통해 많은 수의 negative 사용 가능
- 위키피디아와 CCNet 데이터를 이용해 학습

- train

- 위키피디아와 CCNet 데이터를 혼합한 문서들에 대해 대조학습으로 학습
- 두 개의 데이터를 배치의 절반씩 샘플링

- evaluate

- 질의응답 데이터셋인 Natural Question과 TriviaQA를 이용해 모델 평가
 - 상위 k개의 문서 중 적어도 하나의 정답을 포함하는 질문의 수를 나타내는 top-k retrieval accuracy 측정
- BEIR 벤치마크를 이용해 모델 평가
 - 18개의 검색 데이터셋으로 구성 (사실검증이나 인용예측과 같은 태스크에 대응, 위키피디아나 과학 논문 등 서로 다른 도메인을 포괄)
 - 제로샷 검색에 초점
 - nDCG@10과 Recall@100 평가지표 사용

- supervised가 필요하지 않은 검색
 - BM25, SimCSE, REALM
- ICT를 이용
 - ICT, Masked Salient Spans
- MS MARCO에서 학습된 검색기
 - sparse retriever → Splade v2
 - dense retriever → DPR, ANCE, TAS-B, GenQ
 - late-interaction → ColBERT
 - cross-encoder reranking → BM25+CE

1. Masked Salient spans

: 문서에서 엔티티가 들어있는 문장을 찾고, 그 엔티티만 Mask로 가려서 질의처럼 사용, 가려진 엔티티 span 자체를 “답” 또는 salient span으로 보면서 retriever와 reader를 함께 학습시키는 방식

2. ANCE : DPR 구조에서 retriever 자신이 hard negative를 마이닝하며 MSMARCO로 학습한 dense retriever

3. TAS-B : cross-encoder가 준 점수를 증류해서 bi-encoder에게 가르치는 방식

4. GenQ : 생성모델로 합성 질의-문서 쌍을 만들어 retriever를 학습하는 방법

5. ColBERT : 쿼리/문서의 토큰별 임베딩을 모두 보존해 late interaction(토큰-토큰 max-sim)을 하는 retriever

6. cross-encoder reranking : 1차로 뽑은 top-k에서 cross-encoder를 사용한 reranker를 이용해 재순위

NaturalQuestion과 TriviaQA 성능 평가

	NaturalQuestions			TriviaQA		
	R@5	R@20	R@100	R@5	R@20	R@100
Inverse Cloze Task (Sachan et al., 2021)	32.3	50.9	66.8	40.2	57.5	73.6
Masked salient spans (Sachan et al., 2021)	41.7	59.8	74.9	53.3	68.2	79.4
BM25 (Ma et al., 2021)	-	62.9	78.3	-	76.4	83.2
Contriever	47.8	67.8	82.1	59.4	74.2	83.2
<i>supervised model</i> : DPR (Karpukhin et al., 2020)	-	78.4	85.4	-	79.4	85.0
<i>supervised model</i> : FiD-KD (Izacard & Grave, 2020a)	73.8	84.3	89.3	77.0	83.6	87.7

- Contriever는 BM25와 경쟁적인 성능을 보이며,
NaturalQuestion 데이터에서 Recall@100 기준 약 3포인트 향상을 보임(BM25 78.3 → Contriever 82.1)
- ICT나 Masked salient spans로 학습된 기존 dense retriever 성능을 능가함

1. Salient span

: 문장 안에서 중요한 정보 조각 (고유명사, 엔티티 등)


2. Masked Salient spans

: 문서에서 엔티티가 들어있는 문장을 찾고, 그 엔티티만 Mask로 가려서 질의처럼 사용, 가려진 엔티티 span 자체를 “답” 또는 salient span으로 보면서 retriever와 reader를 함께 학습시키는 방식

3. FiD-KD(Fusion-in-Decoder reader - Knowledge Distillation)

: retriever + reader(검색기가 찾은 문서/패시지에서 정답을 추출하거나 생성) 구조에서 Fusion-in-Decoder reader를 KD로 학습해 QA 성능을 높인 방법

BEIR 벤치마크 성능평가 (Recall@100)



- Contriever는 TREC-COVID와 Touche-2020을 제외한 모든 데이터셋에서 BM25와 경쟁적인 성능을 보임
 - 특히 Recall@100 기준 15개의 데이터셋 중 11개의 데이터셋에서 BM25보다 우수한 성능 달성
 - BM25보다 낮은 성능을 보이는 다른 검색기들의 성능을 능가함

1. REALM (Retrieval-Augment dense retriever)

: 외부 문서 코퍼스에서 관련 문서를 검색하는 retriever를 language model 사전학습 안에 통합해서 검색결과를 보며 mask 언어모델을 학습하는 방법

2. SimCSE

: 문장 임베딩을 위한 단순한 대조학습 프레임워크.

3. Recall@100

: 정답 문서가 상위 100개의 검색 결과 안에 포함되었는지를 측정

BEIR 벤치마크 성능평가 (nDCG@10)

Model (→)	BM25	BERT	SimCSE	REALM	Contriever
Dataset (↓)					
MS MARCO	22.8	0.6	8.8	15.2	20.6
Trec-COVID	65.6	16.6	38.6	20.1	27.4
NFCorpus	32.5	2.5	14.0	24.1	31.7
NQ	32.9	2.7	12.6	15.2	25.4
HotpotQA	60.3	4.9	23.3	40.5	48.1
FiQA-2018	23.6	1.4	14.8	9.7	24.5
ArguAna	31.5	23.1	45.6	22.8	37.9
Tóuche-2020	36.7	3.4	11.6	7.3	19.3
CQADupStack	29.9	2.5	20.2	13.5	28.4
Quora	78.9	3.9	81.5	71.6	83.5
DBPedia	31.3	3.9	13.7	22.7	29.2
SCIDOCS	15.8	2.7	7.4	9.0	14.9
FEVER	75.3	4.9	20.1	42.9	68.2
Climate-fever	21.3	4.1	17.6	14.3	15.5
SciFact	66.5	9.8	38.5	47.1	64.9
Avg.	41.7	8.7	24.6	25.1	36.0
Best on	12	0	1	0	2

- Contriever는 BM25와의 격차를 상당부분 줄이지만, 평균 성능으로 보면 여전히 BM25보다 낮은 성능을 보임
→ TREC-COVID와 Tóuche-2020 데이터셋에서 BM25보다 매우 낮은 성능
- TREC-COVID의 경우 COVID 발병 이전에 수집된 데이터로 학습하여 성능이 낮을 것으로 분석
- Tóuche-2020의 경우 긴 문서를 포함하는데, 긴 문서는 dense retriever들이 잘 처리하지 못하는 것으로 보임

1. BEIR : 다양한 도메인으로 구성된 제로샷 정보검색 성능을 평가하기 위한 표준 벤치마크 데이터셋

2. nDCG@n (Normalized Discounted Cumulative Gain)

: 정보검색 및 추천 시스템에서 랭킹 품질을 평가하는 지표, 상위 n개 결과의 순서와 관련성을 종합적으로 측정

3. Tóuche-2020

: 논쟁적 질문에 대해 온라인 포털에서 수집된 문서들중 적절한 argument를 찾아오는 데이터셋

BEIR 벤치마크 성능평가 (recall@100)

	BM25	DPR	ANCE	TAS-B	Gen-Q	ColBERT	Splade v2	Ours
MS MARCO	65.8	55.2	85.2	88.4	88.4	86.5	-	89.1
Trec-COVID	49.8	21.2	45.7	38.7	45.6	46.4	12.3	40.7
NFCorpus	25.0	20.8	23.2	28.0	28.0	25.4	27.7	30.0
NQ	76.0	88.0	83.6	90.3	86.2	91.2	93.0	92.5
HotpotQA	74.0	59.1	57.8	72.8	67.3	74.8	82.0	77.7
FiQA	53.9	34.2	58.1	59.3	61.8	60.3	62.1	65.6
ArguAna	94.2	75.1	93.7	94.2	97.8	91.4	97.2	97.7
Touche-2020	53.8	30.1	45.8	43.1	45.1	43.9	35.4	29.4
CQADupStack	60.6	40.3	57.9	62.2	65.4	62.4	-	66.3
Quora	97.3	47.0	98.7	98.6	98.8	98.9	98.7	99.3
DBPedia	39.8	34.9	31.9	49.9	43.3	46.1	57.5	54.1
Scidocs	35.6	21.9	26.9	33.5	33.2	34.4	36.4	37.8
Fever	93.1	84.0	90.0	93.7	92.8	93.4	95.1	94.9
Climate-fever	43.6	39.0	44.5	53.4	45.0	44.4	52.4	57.4
Scifact	90.8	72.7	81.6	89.1	89.3	87.8	92.0	94.7
Avg. w/o CQA	63.6	48.3	60.1	65.0	64.2	64.5	64.8	67.1
Avg.	63.4	47.7	60.0	64.8	64.2	64.3	-	67.0
Best on	2	0	0	0	1	0	4	7

- **contriever**는 기존 최고 dense bi-encoder TAS-B(65.0)을 넘어 가장 좋은 성능을 보임 (SOTA)
- 높은 recall@100을 바탕으로 cross-encoder reranking을 적용하면 BEIR nDCG@10에서도 SOTA 달성

BEIR 벤치마크 성능평가 (nDCG@10)

	BM25	BM25+CE	DPR	ANCE	TAS-B	Gen-Q	ColBERT	Splade v2	Ours	Ours+CE
MS MARCO	22.8	41.3	17.7	38.8	40.8	40.8	40.1	43.3	40.7	47.0
Trec-COVID	65.6	75.7	33.2	65.4	48.1	61.9	67.7	71.0	59.6	70.1
NFCorpus	32.5	35.0	18.9	23.7	31.9	31.9	30.5	33.4	32.8	34.4
NQ	32.9	53.3	47.4	44.6	46.3	35.8	52.4	52.1	49.8	57.7
HotpotQA	60.3	70.7	39.1	45.6	58.4	53.4	59.3	68.4	63.8	71.5
FiQA	23.6	34.7	11.2	29.5	30.0	30.8	31.7	33.6	32.9	36.7
ArguAna	31.5	31.1	17.5	41.5	42.9	49.3	23.3	47.9	44.6	41.3
Touche-2020	36.7	27.1	13.1	24.0	16.2	18.2	20.2	36.4	23.0	29.8
CQADupStack	29.9	37.0	15.3	29.6	31.4	34.7	35.0	-	34.5	37.7
Quora	78.9	82.5	24.8	85.2	83.5	83.0	85.4	83.8	86.5	82.4
DBPedia	31.3	40.9	26.3	28.1	38.4	32.8	39.2	43.5	41.3	47.1
Scidocs	15.8	16.6	7.7	12.2	14.9	14.3	14.5	15.8	16.5	17.1
FEVER	75.3	81.9	56.2	66.9	70.0	66.9	77.1	78.6	75.8	81.9
Climate-FEVER	21.3	25.3	14.8	19.8	22.8	17.5	18.4	23.5	23.7	25.8
Scifact	66.5	68.8	31.8	50.7	64.3	64.4	67.1	69.3	67.7	69.2
Avg. w/o CQA	44.0	49.5	26.3	41.3	43.7	43.1	45.1	50.6	47.5	51.2
Avg.	43.0	48.6	25.5	40.5	42.8	42.5	44.4	-	46.6	50.2
Best on	1	3	0	0	0	1	0	1	1	9

- **contriever**는 dense retriever들보다 나은 성능을 보임
- **contriever**에 cross-encoder를 사용한 reranker를 추가로 아용하면 더욱 향상된 성능을 보임 (SOTA)

- 본 논문에서는 dense retriever를 학습하기 위해 대조학습을 이용한 사전학습 진행
 - positive 쌍을 위한 random cropping, 많은 수의 negative 문서를 사용할 수 있는 MoCo 방법을 이용
- 대조학습을 사용해 unsupervised data로 학습된 검색기가 BM25와 경쟁할 수 있는 우수한 검색 성능을 나타냄을 보임
- 추가로 MS MARCO 데이터를 이용해 fine-tuning하여 더욱 개선
- contriever를 이용해 BEIR 벤치마크에서 recall@100 SOTA 달성
- cross-encoder를 추가로 사용해 재순위 하는 것은 BEIR 벤치마크에서 nDCG@10 SOTA 달성



Making the Great! Making the New

감사합니다