

Dense Passage Retrieval for Open-Domain Question Answering

Songwon Park

xlah1386@gs.cwnu.ac.kr

2025. 04. 24

Dense Passage Retrieval for Open-Domain Question Answering

- **Vladimir Karpukhin, Barlas Oguz, Sewon Min, Patrick Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, Wen-tau Yih**

(Facebook AI, University of Washington, Princeton University)

- **EMNLP 2020**
- [paper](#)

Open-Domain Question Answering


- 매우 많은 정보를 포함하고 있는 대량의 문서로부터 주어진 질문에 대한 답을 찾는 문제

1. 질문과 관련된 문서를 찾는 단계
2. Retriever가 검색한 상위 문서를 받아 정답 범위(span)을 찾는 단계

Q: How many of Warsaw's inhabitants spoke Polish in 1933?



**Document
Retriever**



**Document
Reader**

833,500




Figure 1: An overview of our question answering system DrQA.

- Open-Domain Question Answering은 후보 문맥 선정시 passage retrieval에 의존
- 기존 passage retrieval는 키워드 매칭에 효율적인 TF-IDF, BM25 (sparse vector)
 - 동의어, 의역을 매칭하는데 한계
- dense retrieval (dense vector)
 - 완전 다른 토큰으로 구성되어도 동의어나 의역에 해당하는 벡터들은 가깝게 매핑 가능

Q : Who is the **bad guy** in lord of the rings?

A : Sala Baker is best known for portraying the **villain** Sauron in the Lord of the Rings trilogy.

- 좋은 dense vector representation을 학습하려면 많은 (정답이 있는 질문, context) 쌍이 필요



Open Retrieval Question Answering (ORQA)

- ICT(Inverse Cloze Task)를 이용한 추가적인 사전학습 수행
- 질문 인코더와 reader 모델은 (질문, 답변)쌍을 이용해 함께 fine-tuning
 - ➡ ORQA 이후 dense retrieval가 TF-IDF/BM25 보다 우수하다는 것을 입증
- QRQA에서 밀집 검색의 약점
 - ICT 사전학습시 일반 문장이 질문을 대체하는것이 적합한지 명확하지 않음
 - context 인코더는 (질문,답변) 쌍을 이용해 fine tuning 되지 않아 최적이지 아닐 수 있음

메인 아이디어

Open-Domain Question Answering을 위한 passage retrieval

- Open-Domain Question Answering은 후보 문맥 선정시 passage retrieval에 의존
- 기존 passage retrieval는 키워드 매칭에 효율적인 TF-IDF, BM25 (sparse vector)
 - 동의어, 의역을 매칭하는데 한계



간단한 듀얼 인코더를 이용해 적은 수의 질문과 passage로부터 임베딩을 학습하는
dense representation을 이용한 검색

DPR 목표

- passage가 주어진 경우, 저차원 연속 공간에 있는 모든 passage를 인덱스화 한 후 입력 질문과 관련된 상위 k개의 passage를 효율적으로 검색하는 것

Training

- 질문, passage 사이 유사도 계산을 위해 벡터의 내적, 유클리드거리(L2) 이용,
loss 함수를 위한 NLL(Negative Log Likelihood), triplet을 이용

➡ 내적과 NLL loss를 이용한 성능이 가장 좋음

Sim	Loss	Retrieval Accuracy			
		Top-1	Top-5	Top-20	Top-100
DP	NLL	44.9	66.8	78.1	85.0
	Triplet	41.6	65.0	77.2	84.5
L2	NLL	43.5	64.7	76.1	83.1
	Triplet	42.2	66.0	78.1	84.9

Table 6: Retrieval Top-*k* accuracy on the development set of Natural Questions using different similarity and loss functions.

Training

- 유사도 계산시 두 벡터의 내적을 이용

$$\text{sim}(q, p) = E_Q(q)^T E_P(p)$$

- encoder : 두 개의 독립적인 BERT 사용 (출력 : [CLS] 토큰 (768차원))
 - $E_P(\cdot)$: passage를 벡터로 매핑하고 검색에 사용할 passage에 대한 인덱스를 구축하는 dense encoder
 - $E_Q(\cdot)$: 입력 질문을 벡터에 매핑하는 encoder
 - q, p : query, passage

- Loss 계산시 NLL(Negative Log Likelihood) 이용

$$L(q_i, p_i^+, p_{i,1}^-, \dots, p_{i,n}^-) = -\log \frac{e^{\text{sim}(q_i, p_i^+)}}{e^{\text{sim}(q_i, p_i^+)} + \sum_{j=1}^n e^{\text{sim}(q_i, p_{i,j}^-)}}$$

- q_i : query
- p_i^+ : positive passage
- $p_{i,j}^-$: negative passage

Positive and negative passages

- positive passage의 경우 데이터셋이나 답변을 통해 찾을 수 있음.
- negative passage의 경우 선택의 폭이 매우 넓음.
 - (1) Random : 코퍼스에서 랜덤 추출
 - (2) BM25 : BM25에서 반환된 상위 passage 중 답변은 없지만 질문의 토큰과 대부분 일치하는 passage (hard negative)
 - (3) Gold : 다른 질문의 positive passage
 - ➔ 같은 미니배치 내 Gold + one BM25 negative passage가 성능이 가장 우수

In - batch negatives

- 배치 내 질문을 이용해 negative passage를 선정하여 좋은 성능과 함께 연산 효율적으로 진행

Positive and negative passages

- positive passage의 경우 데이터셋이나 답변을 통해 찾을 수 있음.
- negative passage의 경우 선택의 폭이 매우 넓음.
 - (1) Random : 코퍼스에서 랜덤 추출
 - (2) BM25 : BM25에서 반환된 상위 passage 중 답변은 없지만 질문의 토큰과 대부분 일치하는 passage (hard negative)
 - (3) Gold : 다른 질문의 positive passage
 - ➡ 같은 미니배치 내 Gold + one BM25 negative passage가 성능이 가장 우수

In - batch negatives

- 배치 내 질문을 이용해 negative passage를 선정하여 좋은 성능과 함께 연산 효율적으로 진행

1. Natural Questions

- 질문 : Google 검색 질의에서 추출
- 답변 : 주석 작성자가 확인한 위키백과 문서의 일부

2. Trivia QA

- 웹에서 수집한 답변이 담긴 퀴즈 질문 포함

3. Web Questions

- Google Suggest API에서 얻은 QA 데이터

4. CuratedTREC

- Text Retrieval Conference QA dataset, 웹에서 질문 수집

5. SQuAD

- 독해(reading comprehension)을 위한 데이터

Dataset	Train		Dev	Test
Natural Questions	79,168	58,880	8,757	3,610
TriviaQA	78,785	60,413	8,837	11,313
WebQuestions	3,417	2,474	361	2,032
CuratedTREC	1,353	1,125	133	694
SQuAD	78,713	70,096	8,886	10,570

Table 1: Number of questions in each QA dataset. The two columns of **Train** denote the original training examples in the dataset and the actual questions used for training DPR after filtering. See text for more details.

* TREC, WebQ, TriviaQA에서는 (질문, 답변) 쌍만 제공됨 -> BM25에서 정답을 포함하는 가장 높은 순위 지문을 positive로 사용

* 검색된 상위 100개 결과에 정답이 없는 경우 해당 질문 삭제


Training	Retriever	Top-20					Top-100				
		NQ	TriviaQA	WQ	TREC	SQuAD	NQ	TriviaQA	WQ	TREC	SQuAD
None	BM25	59.1	66.9	55.0	70.9	68.8	73.7	76.7	71.1	84.1	80.0
Single	DPR	78.4	79.4	73.2	79.8	63.2	85.4	85.0	81.4	89.1	77.2
	BM25 + DPR	76.6	79.8	71.0	85.2	71.5	83.8	84.5	80.5	92.7	81.3
Multi	DPR	79.4	78.8	75.0	89.1	51.6	86.0	84.7	82.9	93.9	67.6
	BM25 + DPR	78.0	79.9	74.7	88.5	66.2	83.9	84.4	82.3	94.1	78.6

Table 2: Top-20 & Top-100 retrieval accuracy on test sets, measured as the percentage of top 20/100 retrieved passages that contain the answer. *Single* and *Multi* denote that our Dense Passage Retriever (DPR) was trained using individual or combined training datasets (all the datasets excluding SQuAD). See text for more details.

- BM25 + DPR의 경우 $\text{BM25 score} + \lambda \text{sim}(q, p)$ 로 정의
- SQuAD를 제외한 모든 데이터셋에서 DPR은 BM25보다 좋은 성능
 - 주석 작성자들이 지문을 보고 질문을 작성했기에 어휘적 중복이 많아 BM25의 성능이 좋을 수 있음
 - 데이터가 위키백과 문서에서만 수집되어 학습 사례 분포가 편향되어 있음

Sample efficiency

- 얼마나 많은 train 예제가 필요한가?
- 1,000개의 예제만으로 BM25보다 우수한 성능
- 59,000개까지 추가한 경우 정확도 지속적으로 향상



In-batch negative training


- Negative example 선택 방법 차이
- $k \geq 20$ 일 때, random / BM25 / Gold 중 어느 것을 선택하더라도 상위 k 정확도에 큰 영향 없음

Type	#N	IB	Top-5	Top-20	Top-100
Random	7	✗	47.0	64.3	77.8
BM25	7	✗	50.0	63.3	74.8
Gold	7	✗	42.6	63.1	78.3
Gold	7	✓	51.1	69.1	80.8
Gold	31	✓	52.1	70.8	82.1
Gold	127	✓	55.8	73.0	83.1
G.+BM25 ⁽¹⁾	31+32	✓	65.0	77.3	84.4
G.+BM25 ⁽²⁾	31+64	✓	64.5	76.4	84.0
G.+BM25 ⁽¹⁾	127+128	✓	65.8	78.0	84.9

- N : negative example 수
- IB : in-batch training
- G + BM25 (1), (2) : 배치 내에 negative passage 역할을 하는 BM25 negative passage를 1 또는 2개 추가하여 in-batch training

Sample efficiency

- 얼마나 많은 train 예제가 필요한가?
- 1,000개의 예제만으로 BM25보다 우수한 성능
- 59,000개까지 추가한 경우 정확도 지속적으로 향상



In-batch negative training


- In-batch negative
 - 설정하지 않았을 때보다 성능 향상
 - Gold negative passage가
전체 학습 데이터셋 / 배치 내에서 추출
- ➔ 배치 내에서 negative passage를 추출하는 것이 우수한 성능
 - Batch size가 커질수록 더 많은 쌍을 생성하여 학습 예제 수 늘릴 수 있음

Type	#N	IB	Top-5	Top-20	Top-100
Random	7	✗	47.0	64.3	77.8
BM25	7	✗	50.0	63.3	74.8
Gold	7	✗	42.6	63.1	78.3
Gold	7	✓	51.1	69.1	80.8
Gold	31	✓	52.1	70.8	82.1
Gold	127	✓	55.8	73.0	83.1
G.+BM25 ⁽¹⁾	31+32	✓	65.0	77.3	84.4
G.+BM25 ⁽²⁾	31+64	✓	64.5	76.4	84.0
G.+BM25 ⁽¹⁾	127+128	✓	65.8	78.0	84.9

- N : negative example 수
- IB : in-batch training
- G + BM25 (1), (2) : 배치 내에 negative passage 역할을 하는 BM25 negative passage를 1 또는 2개 추가하여 in-batch training

Sample efficiency

- 얼마나 많은 train 예제가 필요한가?
- 1,000개의 예제만으로 BM25보다 우수한 성능
- 59,000개까지 추가한 경우 정확도 지속적으로 향상



In-batch negative training

- Hard negative passage 사용
 - BM25 점수는 높지만 정답 passage는 포함하지 않는 hard negative passage
 - 하나만 추가한 경우 성능이 많이 향상되지만 두 개를 추가한 경우 더 나아지지 않음

Type	#N	IB	Top-5	Top-20	Top-100
Random	7	✗	47.0	64.3	77.8
BM25	7	✗	50.0	63.3	74.8
Gold	7	✗	42.6	63.1	78.3
Gold	7	✓	51.1	69.1	80.8
Gold	31	✓	52.1	70.8	82.1
Gold	127	✓	55.8	73.0	83.1
G.+BM25 ⁽¹⁾	31+32	✓	65.0	77.3	84.4
G.+BM25 ⁽²⁾	31+64	✓	64.5	76.4	84.0
G.+BM25 ⁽¹⁾	127+128	✓	65.8	78.0	84.9

- N : negative example 수
- IB : in-batch training
- G + BM25 (1), (2) : 배치 내에 negative passage 역할을 하는 BM25 negative passage를 1 또는 2개 추가하여 in-batch training

Cross-dataset generalization

- 추가적인 fine tuning 없이 다른 데이터셋이 직접 적용했을 때 일반화가 가능한가?
- Natural Questions 데이터셋을 이용하여 DPR 학습 후
Web Questions, CuratedTREC 데이터셋으로 검증 (top 20 기준)

	Web Q	CuratedTrec
BM25	55.0	70.9
DPR Original	75.0	89.1
DPR cross dataset	69.9	86.3

➡ Top 20에서 기존보다 성능이 떨어졌지만, BM25 보다 우수한 성능을 보임

Qualitative Analysis

Question	Passage received by BM25	Passage retrieved by DPR
What is the body of water between England and Ireland?	Title: British Cycling ... England is not recognised as a region by the UCI, and there is no English cycling team outside the Commonwealth Games. For those occasions, British Cycling selects and supports the England team. Cycling is represented on the Isle of Man by the Isle of Man Cycling Association. Cycling in Northern Ireland is organised under Cycling Ulster, part of the all-Ireland governing body Cycling Ireland. Until 2006, a rival governing body existed, ...	Title: Irish Sea ... Annual traffic between Great Britain and Ireland amounts to over 12 million passengers and of traded goods. The Irish Sea is connected to the North Atlantic at both its northern and southern ends. To the north, the connection is through the North Channel between Scotland and Northern Ireland and the Malin Sea. The southern end is linked to the Atlantic through the St George's Channel between Ireland and Pembrokeshire, and the Celtic Sea. ...
Who plays Thoros of Myr in Game of Thrones?	Title: No One (Game of Thrones) ... He may be "no one," but there's still enough of a person left in him to respect, and admire who this girl is and what she's become. Arya finally tells us something that we've kind of known all along, that she's not no one, she's Arya Stark of Winterfell." "No One" saw the reintroduction of Richard Dormer and Paul Kaye, who portrayed Beric Dondarrion and Thoros of Myr, respectively, in the third season, ...	Title: Pål Sverre Hagen Pål Sverre Valheim Hagen (born 6 November 1980) is a Norwegian stage and screen actor. He appeared in the Norwegian film "Max Manus" and played Thor Heyerdahl in the Oscar-nominated 2012 film "Kon-Tiki". Pål Hagen was born in Stavanger, Norway, the son of Roar Hagen, a Norwegian cartoonist who has long been associated with Norway's largest daily, "VG". He lived in Jtten, a neighborhood in the city of Stavanger in south-western Norway. ...

Table 7: Examples of passages returned from BM25 and DPR. Correct answers are written in **blue** and the content words in the question are written in bold.

- DPR이 BM25에 비해 성능이 우수하지만, 검색된 구절에서 차이 존재
- BM25 : 용어 매칭 방법. 키워드와 passage에 민감하게 매칭
- DPR : 어휘적 변화, 의미적 관계 포착

Training	Model	NQ	TriviaQA	WQ	TREC	SQuAD
Single	BM25+BERT (Lee et al., 2019)	26.5	47.1	17.7	21.3	33.2
Single	ORQA (Lee et al., 2019)	33.3	45.0	36.4	30.1	20.2
Single	HardEM (Min et al., 2019a)	28.1	50.9	-	-	-
Single	GraphRetriever (Min et al., 2019b)	34.5	56.0	36.4	-	-
Single	PathRetriever (Asai et al., 2020)	32.6	-	-	-	56.5
Single	REALM _{Wiki} (Guu et al., 2020)	39.2	-	40.2	46.8	-
Single	REALM _{News} (Guu et al., 2020)	40.4	-	40.7	42.9	-
Single	BM25	32.6	52.4	29.9	24.9	38.1
	DPR	41.5	56.8	34.6	25.9	29.8
	BM25+DPR	39.0	57.0	35.2	28.0	36.7
Multi	DPR	41.5	56.8	42.4	49.4	24.1
	BM25+DPR	38.8	57.9	41.1	50.6	35.8

Table 4: End-to-end QA (Exact Match) Accuracy. The first block of results are copied from their cited papers. REALM_{Wiki} and REALM_{News} are the same model but pretrained on Wikipedia and CC-News, respectively. *Single* and *Multi* denote that our Dense Passage Retriever (DPR) is trained using individual or combined training datasets (all except SQuAD). For WQ and TREC in the *Multi* setting, we fine-tune the reader trained on NQ.

- 검색기의 정확도가 높을 수록 더 우수한 QA 결과
 - SQuAD를 제외한 모든 경우에서 DPR이 검색한 답변이 BM25보다 정확할 가능성 높음
 - 대규모 데이터셋(NQ, TriviaQA)의 경우 single 데이터셋과 multi 데이터셋 비슷한 성능
 - 소규모 데이터셋(WQ, TREC)의 경우 multi 데이터셋 사용시 우수한 성능

**간단한 듀얼 인코더를 이용해 적은 수의 질문과 passage로부터 임베딩을 학습하는
dense representation을 이용한 검색**

- Dense retrieval가 Open domain QA에서 기존 sparse retrieval의 성능을 능가함을 입증.
- 적은 수의 (질문, passage) 쌍으로 질문, passage 인코더를 fine tuning 하는 것만으로도 우수한 성능.
- 추가적 학습 없이도 BM25보다 9 - 19% 좋은 성능을 보임.



Making the Great! Making the New

감사합니다