

Exp4Fuse: A Rank Fusion Framework for Enhanced Sparse Retrieval using Large Language Model-based Query Expansion

Songwon Park

xlah1386@gs.cwnu.ac.kr

2025. 08. 14

Exp4Fuse: A Rank Fusion Framework for Enhanced Sparse Retrieval using Large Language Model-based Query Expansion

- **Liu, Lingyuan and Zhang, Mengxiang**
(The University of Hong Kong)
- **ACL 2025**
- [paper](#)

메인 아이디어

LLM 기반 질의 확장을 통해 희소 검색 성능을 향상시키는 Exp4Fuse

- 대형 언어 모델 (Large Language Model, LLM)이 생성한 가상의 문서를 이용해 질의 확장을 수행하여 정보 검색 성능을 향상시킴
 - 정보 검색 성능은 생성된 문서의 품질에 크게 의존하며, 복잡한 프롬프트 전략과 고급 밀집 검색 기법의 통합을 요구하여 비용이 많이 드는 한계



- 제로샷 LLM 기반 질의 확장을 희소 검색기에 적용하는 방식 제안
- Exp4Fuse
 - 원래 질의와 LLM으로 확장된 질의를 기반으로 각각의 검색 경로를 고려
 - 희소 검색기를 사용해 두 개의 순위 리스트를 생성한 뒤 개선된 역순위 융합 방식으로 결과 통합

- 정보검색, IR(Information Retrieval)은 데이터베이스에서 관련 문서를 추출하는 핵심 기술
 - 검색엔진, 검색 기반 생성 시스템 등에서 필수적인 구성요소
 - 문서 컬렉션을 색인화 하고 사용자의 질의가 주어지면 색인에서 쿼리의 단어와 일치하는 문서 검색 후 순위화
 - 사용자의 질의와 문서 간 간극을 줄이기 위해 질의 확장 (Query Expansion) 방법 이용
 - GPT-3, LLaMA 등 LLM을 이용해 답변을 생성할 수 있는 능력이 크게 향상됨에 따라 이를 이용해 희소 및 밀집 검색에서 질의를 확장하려는 시도
 - LLM 기반 질의 확장의 제약
 1. 메모리 속 구식 코퍼스 : LLM의 학습 데이터가 최신 정보를 반영하지 못할 수 있음
 2. 신뢰성 낮은 텍스트 생성
 3. 도메인 지정 불가능 : 특정 분야의 문서 생성 지정이 어려움
- ➡ 위와 같은 문제들은 가상 문서의 품질과 신뢰성에 영향 + 질의 확장 성능에도 악영향

- 희소 검색 (Sparse Retrieval)

- 쿼리와 문서 간 단어 일치 여부에 따라 문서를 순위화
- 어휘 불일치 문제
- Ex) BM25

➡ 어휘 불일치 문제를 해결하기 위해 문서 및 질의 확장 기법 사용

- 문서를 확장하여 성능을 높이는 docT5query
- 용어 표현을 문맥화하고 희소 활성화를 포함시켜 검색성능을 향상시킨 학습된 희소 검색기 SPLADE
- LLM 기반 질의 확장

- LLM 기반 질의 확장

- 대형 언어 모델을 활용해 사용자의 질의를 받아 가상 참조 문서나 잠재적 답변을 생성함으로써 질의를 확장해 검색 성능을 향상시키는 방법
 - LLM을 퓨샷, 복잡한 프롬프트 방식을 활용해 가상의 문서를 생성하고, 이를 원래 질의와 결합하여 검색에 사용함
- 제로샷 LLM 기반 질의 확장을 사용해 밀집 검색 성능을 향상시킨 HyDE
- 퓨샷 기반 확장을 통해 희소 검색, 밀집 검색 모두 성능을 개선한 query2doc
- 기존 LLM 기반 질의 확장의 한계
 - 학습된 희소 검색기나 fine-tuning된 밀집 검색기의 경우 원본 질의 형식으로 학습되었기 때문에 질의 형식이 맞지 않아 이점이 제한적
 - 프롬프트 설계 및 실행에 높은 계산 비용과 시간 소요

Exp4Fuse

- 원래 질의와 LLM으로 확장한 질의를 모두 사용하여 동일한 희소 검색기를 기반으로 문서를 순위화
- LLM 기반 제로샷 질의 확장을 활용하여 비용 효율적인 방식으로 활용


- 융합 검색

- 정보 검색 분야에서 밀집 검색기는 의미적 유사성을 잘 포함하지만, exact match나 긴 문서검색에는 희소 검색기가 더 효과적
- 최근에는 두 검색기의 장점을 결합한 융합 검색 기법이 시도됨.
- 검색 결과 결합시 다음 중 한 가지 방법을 이용해 결과 결합
 - 어휘 점수와 의미 점수의 볼록 조합 : $\text{sim}_{\text{hyb}}\{q, d\} = \lambda \text{sim}_{\text{dense}}\{q, d\} + \text{sim}_{\text{sparse}}\{q, d\}$
 - 역순위 융합(Reciprocal Rank Fusion, RRF) : 여러 방법으로 순위가 매겨진 검색 결과를 하나의 통합된 결과로 결합하는 알고리즘
- 기존 융합 방식들은 높은 성능을 보이지만, 다수의 검색 모델과 밀집 모델의 사용으로 인해 계산 비용과 리소스 소모가 크다는 단점
- LLM을 결합하는 경우 비용은 더욱 커짐

Exp4Fuse

- 단일 희소 검색기만으로 동작함으로써 계산 및 메모리 자원을 적게 소모하여 실용적


Exp4Fuse



- Exp4Fuse 두 단계
 - 다중 경로 질의 확장 (Multi-route Query Expansion)
 - 경로1 : 원본 질의를 이용해 전통적인 방식(sparse retrieval)으로 문서 검색
 - 경로 2 : LLM 기반 질의 확장을 통해 생성된 가상 문서를 원본 질의와 결합 후 검색
 - 랭킹 융합 (Fusion Ranking)

LLM-based query expansion - route 1

- 원본 질의로 sparse retriever를 이용하여 문서를 검색



LLM-based query expansion - route 2

- 원본 질의가 주어지면 간단한 제로샷 프롬프트를 이용해 가상문서를 생성
 - 이후 생성된 가상문서는 원본 질의와 결합 후 sparse retriever의 입력으로 사용
 - 프롬프트 예시 : “Please write a passage to answer the question.” , “Please write a news passage about the topic.” 등
- Sparse Retriever의 경우 단어의 출현을 기반으로 문서의 관련성을 평가
 - LLM이 생성한 가상 문서의 경우 원본 질의보다 길기 때문에, 단순 결합시 문서가 결합된 전체 질의에서 지나치게 큰 영향을 미침
 - ➡ 원본 질의를 여러 번 반복해 길이를 늘려 가상 문서와 균형을 맞춤

$$q_e = \text{concat}(q_o \times \lambda, r_q)$$

- q_o : 원본 질의
- r_q : 원본 질의를 이용해 LLM으로 생성한 가상 문서
- λ : 원본 질의 반복 횟수를 조절하는 가중치 (논문에서 실험시 5로 설정)
- q_e : 최종 확장 질의

Fusion Ranking

- 두 개의 문서 순위 리스트를 하나의 최종 순위 리스트로 결합하는 과정
- 개선된 역순위 융합(Reciprocal Rank Fusion, RRF) 방법 사용
 - 기존 RRF : 순위가 높은 문서일수록 점수를 크게 줌
 - 개선된 RRF : 두 개의 리스트 모두에 나타나는 문서일수록 최종 점수를 더 높게 부여하며, 각 검색 경로의 중요도에 따라 문서의 랭크 점수 조절

$$FRscore = (w_i + \frac{n}{10}) \cdot \sum_{i=1}^2 \frac{1}{k + r_i}$$

- k : 이상치 랭크 순위의 영향을 줄이기 위해 설정된 상수 (논문에서는 60으로 설정)
- r_i : i 번째 리스트에서 해당 문서의 순위 ($i = 1$ 이면 $r_i = I_{oq}$, $i = 2$ 이면 $r_i = I_{eq}$)
- w_i : 각 리스트의 가중치 (논문에서 실험시 $w_1 = 1, w_2 = 1$ 로 설정)
- $n \in \{1, 2\}$: 해당 문서가 두 리스트 중 몇 개에 나타나는지 나타내는 횟수

➡ 두 검색 경로의 결과를 균형있게 반영,
중복되어 등장하는 문서에 우선순위를 부여하는 방식으로 최종 순위 리스트 생성

- 도메인 내(In-domain) 데이터셋

- MS MARCO : 특정 분야가 아닌 open domain 데이터셋
- TREC2019, TREC2020 : MS MARCO 기반 데이터

- 도메인 외(Out-of-distribution) 저자원 데이터셋

- DBPedia : 위키피디아에 있는 정보를 정리해 쉽게 쓸 수 있도록 구조화한 데이터셋
- FiQA : 금융관련 질문과 답변을 포함한 데이터셋
- News : 뉴스 기사에 대한 데이터셋
- Natural Question : 실제 구글 검색 쿼리 + 위키피디아 답변 기반 Question Answering 데이터셋
- Robust04 : TREC Robust Track에서 사용된 뉴스 기사 기반 데이터셋
- Touche2020 : 사회적인 논쟁적 주제에 대한 내용을 포함한 데이터셋
- SciFact : 과학적 주장과 그에 대한 검증 문장을 포함한 데이터셋

BaseLine & Competitors

- 기본 회소 검색기
 - BM25
 - BM25 + docT5query
- 학습된 회소 검색기 (Learned Sparse Retrievers)
 - uniCOIL : BM25의 하드 네거티브로 학습
 - SPLADE 등
- ...

평가 지표

- 도메인 내 평가
 - MS MARCO : MRR@10 , Recall@1k
 - TREC : MAP, nDCG@10, Recall@1k
- 도메인 외 평가
 - nDCG@10

	MS MARCO dev			TREC DL 19		TREC DL 20		
	MRR@10	R@1k	MAP	nDCG@10	R@1k	MAP	nDCG@10	R@1k
<i>Basic sparse retriever and the associated LLM-augmented variant</i>								
BM25 (Robertson et al., 2009)	18.4*	85.7*	30.1*	50.6*	75.0*	28.6*	48.0*	78.6*
+Exp4Fuse	20.7 ^{+2.3}	91.3 ^{+5.6}	38.7 ^{+8.6}	62.0 ^{+12.4}	87.0 ^{+12.0}	36.3 ^{+12.3}	56.6 ^{+12.6}	87.3 ^{+8.7}
docT5query (Nogueira et al., 2019a)	27.2*	94.7*	40.3*	64.2*	83.1*	40.7*	61.9*	84.5*
+Exp4Fuse	28.7 ^{+1.5}	96.4 ^{+1.7}	47.5 ^{+7.2}	68.5 ^{+4.3}	87.8 ^{+4.7}	45.7 ^{+5.0}	64.2 ^{+2.3}	89.3 ^{+4.8}
<i>Learned sparse retriever</i>								
uniCOIL (Lin and Ma, 2021)	35.0*	95.8*	46.1*	70.2*	82.9*	44.3*	67.5*	84.3*
+Exp4Fuse	36.4 ^{+1.4}	97.4 ^{+1.6}	50.1 ^{+4.0}	73.6 ^{+3.4}	86.5 ^{+3.6}	47.2 ^{+2.9}	70.9 ^{+3.4}	87.7 ^{+3.4}
SLIM ⁺⁺ (Li et al., 2023)	-	-	48.3*	72.5*	86.8*	48.7*	69.2*	87.1*
+Exp4Fuse	-	-	50.6 ^{+2.3}	76.6 ^{+4.1}	87.2 ^{+0.4}	48.8 ^{+0.1}	70.4 ^{+1.2}	88.6 ^{+1.5}
SPLADE ⁺⁺ -v1 (Formal et al., 2022)	36.9*	97.9*	50.5*	73.1*	87.3*	50.0*	72.0*	90.0*
+Exp4Fuse	39.8 ^{+2.9}	98.6 ^{+0.7}	56.7 ^{+6.2}	77.6 ^{+4.5}	93.3 ^{+6.0}	54.3 ^{+4.3}	73.3 ^{+1.3}	92.9 ^{+2.9}
SPLADE ⁺⁺ -v2 (Formal et al., 2022)	36.8*	98.0*	50.0*	73.6*	87.6*	51.4*	72.8*	90.2*
+Exp4Fuse	39.6 ^{+2.8}	98.9 ^{+0.9}	56.6 ^{+6.6}	77.1 ^{+3.5}	93.9 ^{+6.3}	55.8 ^{+4.4}	73.8 ^{+1.0}	93.8 ^{+3.6}
<i>Advanced dense retriever and the associated LLM-augmented variant</i>								
TAS-B (Hofstätter et al., 2021)	34.0	97.5	-	71.2	84.3	-	69.3	-
coCondenser (Gao and Callan, 2021)	38.2	98.4	-	71.7	82.0	-	68.4	83.9
Contriever ^{FT} + HyDE (Gao et al., 2022)	-	-	-	67.4	-	-	63.5	-
SimLM (Wang et al., 2022)	41.1	98.7	-	71.4	-	-	69.7	-
+query2doc (Wang et al., 2023)	41.5	98.8	-	72.9	-	-	71.6	-
+LameR (Shen et al., 2024)	-	-	54.9	76.5	91.1	55.7	75.8	89.5

- 기본 희소 검색기, 학습된 희소 검색기와 결합한 결과 모든 벤치마크 데이터셋에서 향상된 성능을 보임
 - 특히 웹 검색 벤치마크(TREC)에서 뛰어난 성능을 보임
- SPLADE + Exp4Fuse는 밀집 검색기 SimLM에 비해 우수한 성능
 - MS MARCO MRR와 TREC2020 nDCG에서 query2doc보다 약간 낮은 성능을 보임
- SPLADE++ v1 or v2 + ExpFuse는 TREC2019에서 모든 지표에 걸쳐 SOTA를 달성

	DBPedia	FiQA	News	NQ nDCG@10	Robust04	Touche2020	Scifact
<i>Basic sparse retriever and the associated LLM-augmented variant</i>							
BM25 (Robertson et al., 2009)	31.8*	23.6*	39.5*	30.6*	40.7*	44.2*	67.9*
+Exp4Fuse	36.1 ^{+4.3}	24.7 ^{+1.1}	44.8 ^{+5.3}	39.1 ^{+8.5}	46.5 ^{+5.8}	51.2 ^{+7.0}	68.8 ^{+0.9}
docT5query (Nogueira et al., 2019a)	33.1*	25.2*	42.0*	38.1*	43.7*	34.7*	67.5*
+Exp4Fuse	38.9 ^{+5.8}	26.3 ^{+1.1}	48.7 ^{+6.7}	42.8 ^{+4.7}	46.9 ^{+3.2}	39.9 ^{+5.2}	71.3 ^{+3.8}
<i>Learned sparse retriever</i>							
uniCOIL (Lin and Ma, 2021)	33.8	28.9	-	42.5	-	29.8	68.6
SPLADE ⁺⁺ -v1 (Formal et al., 2022)	43.7*	34.7*	41.7*	53.7*	46.6*	24.6*	70.4*
+Exp4Fuse	47.2 ^{+3.5}	36.5 ^{+1.8}	42.5 ^{+0.8}	61.3 ^{+7.6}	53.1 ^{+6.5}	33.3 ^{+8.7}	73.8 ^{+3.4}
<i>Advanced dense retriever and the associated LLM-augmented variant</i>							
TAS-B (Hofstätter et al., 2021)	38.4	29.6	-	46.5	-	22.2	64.4
Contriever + HyDE (Gao et al., 2022)	36.8	27.3	-	-	-	-	69.1
SimLM (Wang et al., 2022)	34.9	-	-	-	-	18.9	62.4
+query2doc (Wang et al., 2023)	38.3	-	-	-	-	25.6	59.5

- 일반적으로 질의가 짧고 모호한 BEIR 데이터셋에서 상당한 성능 향상을 보임
 - 희소 검색기 종류와 관계없이 Exp4Fuse를 결합한 경우 7개의 BEIR 데이터셋에서 우수한 성능을 보임
- docT5query + Exp4Fuse는 SciFact를 제외한 데이터셋에서 우수한 성능
- BM25 + Exp4Fuse는 Touche2020 데이터셋에서 nDCG 성능 SOTA 달성
- SPLADE++ v1 + Exp4Fuse의 경우 다른 방법과 대등하거나 우수한 성능

Method	MS MARCO dev			TREC DL 19			TREC DL 20	
	MRR@10	R@1k	MAP	nDCG@10	R@1k	MAP	nDCG@10	R@1k
<i>Basic sparse retriever and the associated LLM-augmented variant</i>								
BM25 (Robertson et al., 2009)	18.4*	85.7*	30.1*	50.6*	75.0*	28.6*	48.0*	78.6*
+Exp4Fuse	20.7 ^{+2.3}	91.3 ^{+5.6}	38.7 ^{+8.6}	62.0 ^{+12.4}	87.0 ^{+12.0}	36.3 ^{+12.3}	56.6 ^{+12.6}	87.3 ^{+8.7}
+Exp4Fuse_LLaMa	18.9	90.6	34.3	59.7	76.7	31.5	49.1	82.6

- 일반화 성능을 평가하기 위해 오픈소스 LLaMA3-8B 모델을 사용해 추가 실험 진행
 - Exp4Fuse가 GPT4-mini 외에도 다양한 LLM에서 잘 작동한다는 점을 보여줌

- Exp4Fuse
 - LLM 기반 질의 확장을 통해 희소 검색 성능을 향상시키는 새로운 프레임워크 제안
- 기존 질의 확장 방법과 달리 LLM이 생성한 정보를 간접적으로 활용하여 질의 확장 수행
 - 원본 질의를 이용해 검색
 - LLM 기반으로 확장시킨 질의를 이용해 검색
- 두 개의 검색 결과를 개선된 RRF를 이용해 하나의 최종 결과로 결합
- 다양한 벤치마크에서 희소 검색기의 성능을 유의미하게 향상시킴



Making the Great! Making the New

감사합니다