

Shifting from Ranking to Set Selection for Retrieval Augmented Generation

Songwon Park

xlah1386@gs.cwnu.ac.kr

2025. 08. 21

Shifting from Ranking to Set Selection for Retrieval Augmented Generation

- **Lee, Dahyun and Jo, Yongrae and Park, Haeju and Lee, Moontae**
(LG AI Research)
- **ACL 2025**
- [paper](#)

메인 아이디어

추론을 통해 질의의 정보 요구를 식별하고, 집합단위로 최적화하여 선택

- Retrieval-Argumented Generation (RAG)에서의 검색은, 검색된 각 문서가 개별적으로 관련성이 높을 뿐 아니라 포괄적인 정보를 포함해야 함
- 기존 접근 방식 : 개별 문서의 관련성에 기반해 top-k 문서를 재정렬
 - 다중 단계 질문응답 (multi-hop Question Answering)과 같은 복잡한 질의에서 정보 요구를 충족시키지 못함




- SETR
 - 질의의 정보 요구를 Chain-of-Thought 추론을 통해 명시적으로 식별, 집합 단위로 최적화하여 선택하는 새로운 집합 기반 문서 선택 방법 제안
 - 기존의 재정렬기보다 우수한 성능을 보이며 정답률과 검색 품질 향상

- RAG는 LLM이 최신 정보나 도메인 특화 지식을 재학습 없이 활용할 수 있도록 하며, 모델 용량이 충분하지 않을 때 발생하는 환각도 완화
 - RAG의 핵심 구성 요소 중 하나는 검색 및 재정렬 모듈
 - 검색된 정보의 품질이 생성되는 답변의 정확성과 관련성에 직접적으로 영향을 줌
 - 검색의 필요성과 종료 시점을 동적으로 결정하거나 검색과 생성을 번갈아 수행하며 문맥을 확장하는 등의 방법으로 최적화하려 함
 - 위와 같은 다단계 접근법은 자원 소모가 크며, 실제 응용에 제약이 많아 대부분 RAG는 검색엔진을 위해 설계된 단순 top-k 기반 재정렬 모듈을 사용
 - 그러나 RAG는 전통 검색엔진과 다른 정보 요구 특성을 가짐
 - 검색엔진 : 검색 결과의 개별적인 관련성에 집중
 - RAG : 정확한 답변 생성을 위해 다양성/완전성/포괄성을 갖춘 문서 집합이 필요
- ➡ 필수 정보를 모두 커버하고, 중복을 줄여 문서 집합 전체의 품질을 최적화하는 새로운 검색 방식 제안

Task Definition

- 문서 검색 작업
 - 주어진 후보 문서 집합 중, 특정 정보 요구를 충족할 최적의 문서 집합을 선택하는 것으로 정의
 - 전통적으로 재정렬 문제로 다뤄 각 문서를 개별적으로 점수화 후 점수가 높은 문서 선택하는 방식
- 관련성 기반 재정렬만으로는 부족하다 판단
 - ➡ 문서 집합 전체의 관련성, 완전성, 간결성을 동시에 최적화하는 집합 단위 검색 방식 제안
 - 재정렬 과정에서 top-k 값을 수동으로 설정할 필요를 제거해 절차 단순화

SETR: Set-wise passage selection for Retrieval-Argument Generation



- 핵심 절차 (전체 문서에 대해 1차 검색 후 진행. Top-20)

1. 질문에 답하기 위해 필요한 핵심 정보 요구 사항 나열
2. 각 요구 사항에 해당하는 정보를 포함하는 문서 식별
3. 질문에 가장 포괄적이고 다양한 정보를 제공하는 문서 하위집합 선택 (선택 문서 개수 제한 없음)

1. Cot(Chain of Thought) 기반 핵심 정보 요구 식별

- 집합 단위 문서 선택을 위해 질의의 정보 요구를 체계적으로 식별하는 프로세스 설계
 - 제로샷 CoT reasoning을 유도하는 프롬프트를 이용해, 입력 질문을 구체적인 정보 하위 목표로 분해

Passage Selection Prompt of SETR

I will provide you with {num} passages, each indicated by a numerical identifier []. Select the passages based on their relevance to the search query: {question}.

{context}

Search Query: {question}

Please follow the steps below:

Step 1. Please list up the information requirements to answer the query.

Step 2. for each requirement in Step 1, find the passages that has the information of the requirement.

Step 3. Choose the passages that mostly covers clear and diverse information to answer the query. Number of passages is unlimited. The format of final output should be '### Final Selection: [] []', e.g., ### Final Selection: [2] [1].

{num}개의 구절을 제공해 드리겠습니다. 각 문서는 숫자 식별자 []로 표시됩니다. 검색어 {question}과의 관련성을 기준으로 문서를 선택하세요.

{context}

Search Query : {question}

다음 단계를 따르세요.

1단계. 질의에 답하기 위한 정보 요구 사항을 나열하세요.

2단계. 1단계의 각 요구 사항에 대해 해당 요구 사항의 정보가 포함된 문서를 찾으세요.


3단계. 질의에 답하기 위해 명확하고 다양한 정보를 주로 다루는 문서를 선택하세요. 문서 수에는 제한이 없습니다. 최종 출력 형식은 '### 최종 선택: [] []', 예: ### 최종 선택: [2] [1]이어야 합니다.



Q. Which company, recently mentioned in articles by 'The Age' and 'TechCrunch', is accused of both **manipulating search results to maximize ad revenue** and **siphoning off news publishers' content and ad revenue**, while **also claiming superior performance for its AI model Gemini compared to competitors**, despite only **releasing a 'lite' version known as Gemini Pro**?

3. 질문에 대해 가장 포괄적이고 다양한 정보를 제공하는 문서 하위집합 선택

- 1차 검색 단계에서 검색된 후보 문서들과 질의를 함께 LLM의 입력으로 사용
- 요구사항을 종합적으로 커버하는 최적의 문서 선택
 - 세밀한 분석, 효과적인 집합 선택 가능
 - 모든 후보 문서를 반드시 포함할 필요 없음
 - 최종 선택 결과에 순서 부여 안함



Retrieval	Model	# of Passages	HotpotQA		2WikiMultiHopQA		MuSiQue		MultiHopRAG
			EM	F1	EM	F1	EM	F1	Accuracy
BM25	RETRIEVAL ONLY								
	-	5.00	26.90	25.86	29.79	21.79	5.46	8.22	39.20
	RERANKING								
	bge-reranker-large	5.00	29.71	28.08	30.16	21.84	6.12	10.00	42.13
	RankLlama	5.00	29.48	27.82	30.30	21.91	6.04	9.26	42.09
	RankVicuna	5.00	28.69	27.31	30.46	22.42	5.99	9.03	40.53
	RankZephyr	5.00	28.96	27.76	30.29	22.34	6.78	10.03	40.10
	FirstMistral	5.00	26.71	26.10	30.15	21.97	5.29	8.42	40.29
	RankGPT (gpt-4o)	5.00	30.89	29.24	31.71	23.31	6.91	9.98	44.36
	SET SELECTION (OURS)								
	SetR-Selection only	2.95	<u>31.61</u>	<u>30.55</u>	32.22	24.20	8.02	11.07	43.62
	SetR-CoT	2.48	30.79	30.12	32.07	24.43	<u>7.03</u>	<u>10.87</u>	41.63
	SetR-CoT & IRI	2.63	32.20	30.57	<u>32.17</u>	<u>24.22</u>	6.62	10.57	<u>44.13</u>
bge-large-en-v1.5	RETRIEVAL ONLY								
	-	5.00	30.07	30.97	31.17	25.22	7.44	10.78	41.82
	RERANKING								
	bge-reranker-large	5.00	32.48	33.24	31.92	25.47	8.06	12.50	43.50
	RankLlama	5.00	31.88	32.95	32.24	25.78	7.61	11.77	43.51
	RankVicuna	5.00	32.08	32.83	32.66	26.85	7.78	11.35	42.76
	RankZephyr	5.00	31.83	32.97	32.68	26.59	8.02	11.72	41.55
	FirstMistral	5.00	30.10	31.07	31.43	25.31	6.53	10.64	42.05
	RankGPT (gpt-4o)	5.00	33.85	34.45	34.36	28.06	9.43	13.25	45.69
	SET SELECTION (OURS)								
	SetR-Selection only	3.41	36.68	37.84	34.84	29.40	<u>10.38</u>	<u>15.28</u>	<u>46.20</u>
	SetR-CoT	2.88	36.46	38.20	<u>35.34</u>	<u>30.34</u>	9.76	14.31	45.26
	SetR-CoT & IRI	2.91	<u>36.62</u>	<u>38.11</u>	35.44	30.35	10.79	15.43	47.14

- 질의응답 평가

- 정답률 측면에서, SETR는 최적의 문서 집합을 선택함으로써 다른 비교모델보다 높은 F1과 Accuracy를 달성

Model	RANK-BASED		PRESENCE-BASED	
	MRR@10	NDCG@10	Prec@5	Recall@5
RETRIEVAL ONLY				
BM25	0.4429	0.6827	0.1109	0.2413
bge-large-en-v1.5	0.4523	0.6900	0.1612	0.3232
RERANKING				
bge-reranker-large	0.6019	0.7481	0.1619	0.3276
RankLlama	<u>0.6311</u>	0.7703	0.1679	0.3375
RankVicuna	0.5077	0.7232	0.1372	0.2760
RankZephyr	0.5326	0.7046	0.1340	0.2685
FirstMistral	0.4521	0.6895	0.1321	0.2671
RankGPT (gpt-4o)	0.6358	<u>0.7628</u>	0.1799	<u>0.3601</u>
SET SELECTION (OURS)				
SETR-Selection only	0.5610	0.7295	<u>0.2187</u>	0.3554
SETR-CoT	0.5533	0.7281	<u>0.2047</u>	0.3413
SETR-CoT & IRI	0.5742	0.7255	0.2268	0.3669

- 검색 평가
 - 순위 기반 지표(rank-based)와 존재 기반 지표(presence-based)를 모두 사용
- SETR는 모든 비교 모델보다 precision(정밀도)에서 향상된 성능을 보임

- SETR
 - 생성형 모델의 고유한 정보 요구를 더 잘 충족하기 위한 집합 단위 선택 접근 제안
 - 정보 요구 식별과 CoT 추론을 이용해 문서를 선택하여 검색 정밀도를 높이도록 함
- 성능이 초기 1단계 검색 결과에 좌우됨
 - 초기 검색 집합에 중요 정보가 없다면 최적 집합을 선택하더라도 누락된 지식 보완이 어려움
- 추론 기반 선택을 위해 사용하는 LLM 품질에 의존적
- 향후 대규모 문서에서 효율적인 선택이 가능하도록 하는 것이 목표



Making the Great! Making the New

감사합니다