

SparTerm: Learning Term-based Sparse Representation for Fast Text Retrieval

Songwon Park

xlah1386@gs.cwnu.ac.kr

2025. 01. 22.

SparTerm: Learning Term-based Sparse Representation for Fast Text Retrieval

- **Yang Bai, Xiaoguang Li, Gang Wang, Chaoliang Zhang, Lifeng Shang, Jun Xu, Zhaowei Wang, Fangshan Wang, Qun Liu**

(Tsinghua University, Huawei Noah's Ark Laboratory)

- **ArXiv 2020**
- [paper](#)

검색기를 통한 문서 검색

- 용어 기반 희소 표현(term-based sparse representation)
 - 문서와 쿼리를 매칭하여 literal matching 효율적으로 수행
 - 표현 용량(representation capacity) 부족, 의미적 매칭에 한계
 - Ex) BoW, BM25
- 밀집 표현(dense representation)
 - 의미적 매칭(semantic matching)에서 우수
 - 자연어 처리에서 희소 표현보다 우수
 - 긴 문서 검색 / exact matching에 한계

1. Represent capacity(표현 용량)

: 얼마나 많은 정보를 담을수 있는지

2. Exact matching

: 쿼리와 문서 내용이 정확히 일치하는 것(100% 일치해야 함)

3. Literal matching

: 쿼리와 문서 간 단어 수준 일치

Bag-of-Words

- 단어들의 순서는 고려하지 않고 출현 빈도에만 집중하는 텍스트 데이터 수치화 표현 방법
- 단일 단어들의 집합으로 변환하고 각 용어에 대해 가중치 부여

ex) "I am student" >> BoW : {"I", "am", "student"}

PLM(Pre-trained Language Model)s for dense text retrieval

- 밀집 표현을 기반으로 질문답변에 대한 passage를 검색하기 위한 FAISS
 - 쿼리와 문서 간 효율적인 상호작용을 수행하기 위한 Col-BERT
- ➡ 긴 문서 검색 / exact match에 한계

PLM(Pre-trained Language Model)s for sparse text retrieval

- 맥락화된 정보를 고려해 용어의 가중치를 추정하기 위한 DeepCT
 - 사용자가 할 수도 있는 쿼리를 예측해 통해 문서를 확장하는 Doc2query
- ➡ 희소 표현을 개선하는데 도움이 되는 보조 중간 모델 학습


메인 아이디어

사전학습된 모델의 심층적 지식을 용어 기반 희소표현으로 전환해 의미적 매칭의 장점 유지와 문제 해결

- 사전학습된 언어모델의 심층적 지식(deep knowledge)을 용어 기반 희소 표현으로 전환
- BoW(Bag of Words) 방법의 표현 용량을 개선하는 동시에 장점을 유지
- 전체 vocab space에서 용어 기반 희소표현을 직접 학습



- 중요도 예측기와 게이팅 컨트롤러로 이루어진 SparTerm 제안




(b) Importance Predictor

- BERT 기반 인코더를 사용해 입력 passage p 내의 용어에 대한 임베딩(h_i)을 얻음
- 각 임베딩은 passage의 주제와 의미적으로 관련된 용어를 파악할 수 있도록 함
- 토큰별로 중요도 예측기 사용시 각 임베딩에 대해 vocab size v의 밀집 중요도 분포(I_i)를 얻음
- 중요도 예측 모듈은 BERT의 MLM(Masked Language Model) head와 유사

$$I_i = \text{Transform}(h_i)E^T + b$$

- Transform : GELU(Gaussian Error Linear Unit) 활성화 함수 및 정규화를 이용한 선형변환
- E : 공유 단어 임베딩 행렬
- b : 바이어스

Passage-wise Importance Distribution(dense)




(b) Importance Predictor

- 최종 passage별 중요도 분포는 토큰별 중요도 분포의 합

$$I = \sum_{i=0}^L Relu(I_i)$$

- L : passage p의 시퀀스 길이
- Relu 활성화 함수 사용 : 0보다 작은 값은 0을 출력




(c) Gating Controller

- passage에 나타나는 용어(literal 용어)는 활성화
- Passage 주제와 관련된 용어도 활성화 되어야 함

➔ Literal 전용 게이팅 컨트롤러

➔ 확장 게이팅 컨트롤러




(c) Gating Controller

- Literal 전용 컨트롤러
- 원래 passage에 있는 용어만 활성화 됨

$$G(p) = BOW(p)$$

- $BOW(p)$: passage p에 대한 이진 BOW 벡터



(c) Gating Controller

- 밀집 표현을 통해 의미적으로 중요한 용어 고려
- 차원 v 의 passage 별 밀집 용어 게이팅 분포(G) 얻음
(각 용어가 최종 희소 표현에 참여할 확률)

- 중요도 예측기와 유사한 구조를 가짐.

- 희소성을 보장하기 위해 이진화기 적용

$$G' = \text{Binarizer}(G)$$

- 확장용어에 대한 게이팅 벡터


- 이진화기 적용된 벡터와 not bow 벡터의 요소별(element-wise) 곱

$$G_e = G' \odot (\neg BOW(p))$$

원본 텍스트에 있는 단어들: not bow에서 0

원본 텍스트에 없지만 확장될 단어들: G' 에서 1, not bow에서 1


원본 텍스트에 없고 확장되지 않을 단어들: G' 에서 0




(c) Gating Controller

- 최종 확장 강화 게이팅 벡터
- 어휘적 불일치를 해결할 수 있는 용어 활성화


$$G_{l_e} = G_e + BOW(p)$$



(a) SparTerm Model



(b) Importance Predictor



(c) Gating Controller

- 중요도 예측기와 게이팅 컨트롤러의 결과를 이용해 요소별(element wise) 곱

$$p' = F(p) \odot G(p)$$

- 학습 데이터 : 쿼리 q_i , 긍정적 passage(관련 높은 passage) $p_{i,+}$, 부정적 passage(관련성 낮은 passage) $p_{i,-}$
- Loss 함수는 관련 문서에 대한 negative log likelihood

$$L_{rank}(q_i, p_{i,+}, p_{i,-}) = -\log \frac{e^{\text{sim}(q'_i, p'_{i,+})}}{e^{\text{sim}(q'_i, p'_{i,+})} + e^{\text{sim}(q'_i, p'_{i,-})}}$$

- $q'_i, p'_{i,+}, p'_{i,-}$: 식 $p' = F(p) \odot G(p)$ 에 의해 얻어진 $q_i, p_{i,+}, p_{i,-}$ 의 희소 표현
- Sim : dot product와 같은 유사도 계산 식

Term expansion	Description and examples
Passage2query	Expand words that tend to appear in corresponding queries, i.e. “how far”, “what causes”.
Synonym	Expand synonym for original core words, i.e. “cartoon”->“animation”.
Co-occurred words	Expand frequently co-occurred words for original core words, i.e. “earthquakes”->“ruins”.
Summarization words	Expand summarization words that tend to appear in passage summarization or taggings.

Table 1: Different kinds of term expansion.

- 사전학습된 BERT는 동의어와 동시에 발생하는 단어에 대해 확장 가능
- 본 논문에서는 passage2query, summarization 용어를 확장하는데 중점을 둠
- 이진 cross entropy loss를 이용해 vocab의 모든 용어의 확률값 최대화

$$L_{exp} = -\lambda_1 \sum_{j \in m | T_m=0} \log(1 - G_j) - \lambda_2 \sum_{k \in m | T_m=1} \log G_k$$

- λ_1 : 확장되지 않아야 할 단어들에 대한 손실 가중치
- λ_2 : 목표 텍스트에 나타나는 단어들에 대한 손실 가중치 (λ_1 보다 크게 설정하여 많은 단어가 확장되도록 장려)
- T : 해당 타겟 텍스트의 이진 BoW 벡터
- G : 이진화기 적용 전 밀집 벡터.

최종 Loss

$$L = L_{rank} + L_{exp}$$

Dataset

- MS MARCO passage retrieval dataset
 - 공개된 MSMARCO 데이터셋 기반, Bing에서 사용자의 질의에 대해 수집한 웹 페이지의 passage
- MS MARCO Document Retrieval dataset
 - MSMARCO passage retrieval dataset의 passage를 포함하는 문서 기반

Implementation

- BERT와 동일한 hyper parameter
- 중요도 예측기
 - 사전학습된 google BERT로 초기화
 - 토큰별 중요도 예측기 매개변수는 BERT MLM head로 초기화
- 확장-강화 게이팅 컨트롤러
 - BERTbase로 초기화
 - 이진화기 임계값 0.7
- Adam optimizer

- Baseline (희소 표현에 기반한 방법)
 - BM25 : 빈도 기반 BOW 검색 모델 (가중치 조정에 초점)
 - DeepCT : 용어 가중치 모델 (가중치 조정에 초점)
 - Doc2query : Transformer를 이용한 문서 확장 방법 (내용과 관련된 용어로 문서 확장)
 - Doc2query - T5 : 문서 확장을 위한 쿼리 생성을 위해 T5 언어 모델 활용
- Setting
 - SparTerm (literal - only) : 중요도 예측기 + literal 전용 게이팅 컨트롤러
 - SparTerm (Expansion - only) : 중요도 예측기 + 확장 게이팅 컨트롤러
 - SparTerm (Expansion - enhanced) : 중요도 예측기 + 확장 강화 게이팅 컨트롤러

Model	MRR@10	R@10	R@20	R@50	R@100	R@200	R@500	R@1000
BM25	18.6	-	49	60	69	75	82	85.71
Doc2query	21.5	-	-	-	-	-	-	89.1
Doc2query-T5	27.7	-	-	75.6	81.89	86.88	91.64	94.7
DeepCT	24.3	49	58	69	76	82	86	91
SparTerm(literal-only)	27.46	51.05	60.21	71.55	78.28	83.27	88.33	91.16
SparTerm(expansion-only)	19.8	40.93	-	63.42	70.96	77.62	84.81	89.08
SparTerm(expansion-enhanced)	27.94	51.95	61.58	72.48	78.95	84.05	89.5	92.45

Table 2: Performances of different models on Dev Set of MSMARCO Passage Retrieval dataset.

- SparTerm (expansion-enhanced)는 Recall에서 Doc2query-T5를 제외하고 모든 baseline을 능가하여 제일 좋은 성능을 보임
- 확장 없이도 SparTerm (literal-only)는 DeepCT보다 좋은 성능을 보임
- SparTerm (expansion-only)는 BM25보다 좋은 성능을 보임

Model	MRR@10
BM25+ <i>PassageRetrievalMax</i>	23.6
HDCT+ <i>PassageRetrievalMax</i>	26.1
BM25	24.5
HDCT(sum)	28.0
HDCT(decay)	28.7
SparTerm(literal-only)+ <i>PassageRetrievalMax</i>	28.5
SparTerm(expansion-enhanced)+ <i>PassageRetrievalMax</i>	29.0

Table 3: Performance of baselines and our models on dev set of MSMARCO document ranking dataset. All use the max score of passages in the document as the document score at the query time.

- 각 문서를 passage로 나눠 passage의 희소표현 생성
- *PassageRetrievalMax* : 문서의 passage 점수 계산해 문서 점수로 최대값 선택
- HDCT : DeepCT 기반으로 문서 ranking 초점
 - Passage 표현의 합
 - 감소된 가중치 합


- ➡ 문서를 passage로 나누어 학습 되었음에도 문서 검색에 좋은 성능을 보임
- ➡ Sparterm이 생성한 희소 표현으로 긴 문서 검색도 가능

Query	Type	DeepCT	SPART
Can hives be a sign of pregnancy?	Literal term Weights	hives are caused by allergic reactions . the dryness and stretching of your skin along with other changes can make you more susceptible to experiencing hives during pregnancy . hives can be caused by an allergic reaction to almost anything . some common causes of hives during pregnancy are noted below : medicine .	hives are caused by allergic reactions . the dryness and stretching of your skin along with other changes can make you more susceptible to experiencing hives during pregnancy . hives can be caused by an allergic reaction to almost anything . some common causes of hives during pregnancy are noted below : medicine
	Term expansion		symptoms:1.0, women:0.99, rash:0.98, feel:0.99, causing:0.97, body:0.96, affect:0.96, baby:0.94, pregnant:0.93, sign:0.91, ...
Temperature in April in Bali	Literal term Weights	weather in bali in april with greatly reduced humidity levels (around 65 %) , april heralds the end of bali's wet season . monthly rainfall is reduced to 70 millilitres on average , the days are clearer and that classic bali heat is on the rise with some days reaching 33 c .	weather in bali in april with greatly reduced humidity levels (around 65 %) , april heralds the end of bali's wet season . monthly rainfall is reduced to 70 millilitres on average , the days are clearer and that classic bali heat is on the rise with some days reaching 33 c
	Term expansion		month:0.99, rain:0.98, temperature:0.97, Java:0.97, summer:0.95, tropical:0.93, monsoon:0.93, hot:0.84, climate: 0.83...
Effects of detox juice cleanse	Literal term Weights	unhealthy weight loss . one of the positive side effects of a detox cleanse is weight loss . however , according to the same review article in obesity reviews , you ' re not losing fat weight on such a severe diet , but precious muscle mass	unhealthy weight loss . one of the positive side effects of a detox cleanse is weight loss . however , according to the same review article in obesity reviews , you ' re not losing fat weight on such a severe diet , but precious muscle mass
	Term expansion		benefits:0.99, good:0.99, bad:0.99, harmful:0.98, vitamin:0.97, drugs:0.93, body:0.98, cause:0.97, definition:0.85, heavy:0.84

Figure 3: Term weightings of different passages weighted by DeepCT and SparTerm, and the expanded terms with their probabilities (before the binarization) predicted by SparTerm. The depth of the color represents the term weights, deeper is higher.

- Sparterm(literal-only)와 DeepCT (세 가지 쿼리에 대한 용어의 중요도)
 - Sparterm : 쿼리에 나타나지 않아도 많은 용어를 활성화
 - DeepCT : 매우 적은 수의 용어만 활성화 ('알러지 반응'과 같은 중요 용어가 누락될 수 있음)

Temperature in April in Bali	Literal term Weights	weather in bali in april with greatly reduced humidity levels (around 65 %) , april heralds the end of bali's wet season . monthly rainfall is reduced to 70 millilitres on average , the days are clearer and that classic bali heat is on the rise with some days reaching 33 c .	weather in bali in april with greatly reduced humidity levels (around 65 %) , april heralds the end of bali's wet season . monthly rainfall is reduced to 70 millilitres on average , the days are clearer and that classic bali heat is on the rise with some days reaching 33 c
	Term expansion		month:0.99, rain:0.98, temperature:0.97 , Java:0.97, summer:0.95, tropical:0.93, monsoon:0.93, hot:0.84, climate: 0.83...



- 확장된 용어의 세 가지 유형

- Passage2query 용어 (temperature)
- 원래 용어의 동의어 (weather / climate, rainfall / rain)
- 원래 용어와 함께 자주 나타나는 용어 (season, hot >> summer)

- SparTerm
 - 중요도 예측기와 게이팅 컨트롤러로 구성
 - 전체 vocab 공간에서 용어 기반 희소 표현을 학습하도록 제안
 - 의미적 매칭과 용어적 매칭에 좋은 성능을 보임
- MS MARCO 데이터셋에서 수행한 실험은 비슷한 크기의 사전학습모델을 기반으로 한 이전 희소 모델보다 우수한 성능을 보이며, 모든 희소 모델 중에서 SOTA를 달성



Making the Great! Making the New

감사합니다